CLASE 20: LEY DE LOS GRANDES NÚMEROS

1. Método de los Momentos para Estimar un Parámetro

- Una tarea propia de la estadística es conocer medidas generales de una población en base a datos sueltos y limitados.
- Para eso, podemos asumir que cierto fenómeno medible (en el sentido físico) sigue una distribución. Digamos que la estatura humana es $H \sim \mathcal{N}(\mu; 0,15)$.
- Tomamos muchas medidas hasta obtener una muestra:

$$(H_i)_{i\geq 1}^{N} \sim H$$

$$\frac{1}{n}\sum_{i=1}^{N} H_i \approx \mathbb{E}(H) = \mu$$

$$\mu \approx \overline{H} = \frac{1}{N}\sum_{i=1}^{N} H_i$$

1.1. Ejemplo: Distribución geométrica. $X \sim \mathcal{G}(\theta)$.

- Tenemos una muestra $(X_i)_{i=1}^{N}$

$$\frac{1}{N}\sum X_i = \mathbb{E}(X_1)$$

$$\frac{1}{N}\sum X_i \approx \frac{1}{\theta}$$

$$\theta \approx \frac{1}{\frac{1}{N}\sum X_i}$$

1.2. Usamos el segundo momento para la misma muestra:

$$\frac{1}{n}\sum X_i^2 = \mathbb{E}\left(X_1^2\right)$$

$\mathbb{V}(X_1) = \mathbb{E}\left(X_1^2\right) - \mathbb{E}^2(X_1)$
$\mathbb{V}(X_1) + \mathbb{E}^2(X_1) = \mathbb{E}\left(X_1^2\right)$

$$\begin{aligned}\frac{1}{n}\sum X_i^2 &= \mathbb{V}(X_1) + \mathbb{E}^2(X_1)\\ &= \frac{1-\theta}{\theta^2} + \frac{1}{\theta^2}\\ &= \frac{2-\theta}{\theta^2}\end{aligned}$$

$\frac{1}{n}\sum X_i^2 = \overline{Y}$

$$\overline{Y} = \frac{2-\theta}{\theta^2}$$

$$\overline{Y}\theta^2 + \theta - 2 = 0$$

- Tenemos que elegir la solución no negativa.

$$\theta_{1;2} = \frac{-1 \pm \sqrt{1 - 4\left(\overline{Y}\right)(-2)}}{2\overline{Y}}$$

1.3. Ejercicio de Breakout:

Sea $(X_i)_{i=1}^N$ una muestra aleatoria (iid) de distribución $\mathcal{E}(\theta)$.

- Hallar un estimador de momentos de $q(\theta) = P(X_1 \geq 1)$ basado en $g(x) = \underset{(1;\infty)}{\mathbf{1}}(x)$.
- Deducir un estimador de θ usando el hallado previamente.

1.3.1. Primera parte.

$$\mathbb{E}\left(\underset{(1;\infty)}{\mathbf{1}}(x)\right) = P(x \in (1;\infty))$$

$$\frac{1}{n}\sum_i \underset{(1;_i\infty)}{\mathbf{1}}(x) = \mathbb{E}\left(\underset{(1;\infty)}{\mathbf{1}}(x_i)\right)$$

$$\frac{1}{n}\sum_{i=1}^n \underset{(1;\infty)}{\mathbf{1}}(x_i) \approx P(X_1 \geq 1)$$

1.3.2. Segunda Parte (encontrar el parámetro θ).

$$\frac{1}{n}\sum_{i=1}^n \underset{(1;\infty)}{\mathbf{1}}(x_i) \approx P(X_1 \geq 1)$$

$$\frac{1}{n}\sum_{i=1}^n \underset{(1;\infty)}{\mathbf{1}}(x_i) \approx 1 - \left(1 - e^{-\theta}\right)$$

$$\frac{1}{n}\sum_{i=1}^n \underset{(1;\infty)}{\mathbf{1}}(x_i) \approx e^{-\theta}$$

$$\ln\left[\frac{1}{n}\sum_{i=1}^n \underset{(1;\infty)}{\mathbf{1}}(x_i)\right] \approx \ln e^{-\theta}$$

$$-\ln\left[\frac{1}{n}\sum_{i=1}^n \underset{(1;\infty)}{\mathbf{1}}(x_i)\right] \approx \theta$$

2. Breakout

Sean las $(X_i)_{i\geq 1}$ v.a. idénticamente distribuidas e independientes y sea $f : \mathbb{R}^3 \to \mathbb{R}$ una función continua. Para cada $n \in \mathbb{N} : Y_n = f(X_n; X_{n+1}; X_{n+2})$.

Asumimos que $\exists \mathbb{E}(Y_1) < \infty$. Probar

$$\frac{\sum_{i=1}^n Y_i}{n} \overset{n\to\infty}{\longrightarrow} \mathbb{E}(Y_1)$$

2.1. Solución.

- El problema es que no tenemos V.A. independientes en $\sum_{i=1}^{n} Y_i$.

La estructura de dependencia es bastante sencilla:

Y_1 es no independiente sólo con las Y_i que son función de $(X_1; X_2; X_3)$. Estas son $Y_2 = f(X_2; X_3; X_4)$ e $Y_3 = (X_3; X_4; X_5)$. Ninguna de las tres variables que definen a Y_1 aparece nunca más y por lo tanto sabemos que es independiente de todas las demás variables aleatorias Y_i.

$$A_i = Y_{3i}$$

$$B_i = Y_{3i-1}$$

$$C_i = Y_{3i-2}$$

$(A_i)_{i\geq 1} = Y_3; Y_6; Y_9...$
$(B_i)_{i\geq 1} = Y_2; Y_5; Y_8...$
$(C_i)_{i\geq 1} = Y_1; Y_4; Y_7...$

$$\frac{\sum_{i=1}^{n} Y_i}{n} = \frac{\sum_{i=1}^{\lfloor \frac{n}{3} \rfloor} A_i + \sum_{i=1}^{\lfloor \frac{n}{3} \rfloor} B_i + \sum_{i=1}^{\lfloor \frac{n}{3} \rfloor} C_i}{n} = \frac{\lfloor \frac{n}{3} \rfloor}{n} \left(\frac{\sum_{i=1}^{\lfloor \frac{n}{3} \rfloor} A_i}{\lfloor \frac{n}{3} \rfloor} + \frac{\sum_{i=1}^{\lfloor \frac{n}{3} \rfloor} B_i}{\lfloor \frac{n}{3} \rfloor} + \frac{\sum_{i=1}^{\lfloor \frac{n}{3} \rfloor} C_i}{\lfloor \frac{n}{3} \rfloor} \right)$$

$$\frac{\lfloor \frac{n}{3} \rfloor}{n} \left(\frac{\sum_{i=1}^{\lfloor \frac{n}{3} \rfloor} A_i}{\lfloor \frac{n}{3} \rfloor} + \frac{\sum_{i=1}^{\lfloor \frac{n}{3} \rfloor} B_i}{\lfloor \frac{n}{3} \rfloor} + \frac{\sum_{i=1}^{\lfloor \frac{n}{3} \rfloor} C_i}{\lfloor \frac{n}{3} \rfloor} \right) =$$

$$\frac{\sum_{i=1}^{\lfloor \frac{n}{3} \rfloor} A_i}{\lfloor \frac{n}{3} \rfloor} \to \mathbb{E}(Y_1)$$

$$\frac{\sum_{i=1}^{\lfloor \frac{n}{3} \rfloor} B_i}{\lfloor \frac{n}{3} \rfloor} \to \mathbb{E}(Y_1)$$

$$\frac{\sum_{i=1}^{\lfloor \frac{n}{3} \rfloor} C_i}{\lfloor \frac{n}{3} \rfloor} \to \mathbb{E}(Y_1)$$

$$\lim_{n} \frac{\lfloor \frac{n}{3} \rfloor}{n} \left(\frac{\sum_{i=1}^{\lfloor \frac{n}{3} \rfloor} A_i}{\lfloor \frac{n}{3} \rfloor} + \frac{\sum_{i=1}^{\lfloor \frac{n}{3} \rfloor} B_i}{\lfloor \frac{n}{3} \rfloor} + \frac{\sum_{i=1}^{\lfloor \frac{n}{3} \rfloor} C_i}{\lfloor \frac{n}{3} \rfloor} \right) = \frac{1}{3} 3\mathbb{E}(Y_1)$$

3. Teorema de la Codifiación de una Fuente de Shannon

Queremos codificar los mensajes que nos llegan de una fuente usando un conjunto de símbolos predeterminado de largo fijo. Esto se puede entender en el contexto de la codificación digital de mensajes.

- Existe un alfabeto, el conjunto A. Este define un diccionario de palabras de largo n, A^n.
- Recibimos señales aleatorias formadas por elementos de A, $(X_i)_{i\geq 1}$. Los X_i son iid $\forall a : P(X_i = a) = \rho(a)$, donde ρ es una densidad en A.
- Llamemos a $\boldsymbol{X}_n$ un bloque de datos o palabra, $\boldsymbol{X}_n = (X_1; X_2; ...; X_n)$.
- Queremos identificar una palabra a través de la respuesta a una cantidad fija de preguntas booleanas (sí o no). Queremos hacerlo con una precisión arbitraria ε.

- Queremos encontrar un conjunto de palabras $C \subset A^n$ tal que $P(\boldsymbol{X}_n \in C) \geq 1-\varepsilon$.
- Para buscamos $\min |C| \leq 2^l$.
- Elegimos $C' \in \{0;1\}^l$ y una biyección $\varphi : C \to C'$, de tal forma que toda palabra $w \in C$ queda asociada a $\varphi(w) \in C'$. Su inversa $\psi(w)$ recupera desde el código binario la palabra original.
- Las palabras del resto del diccionario, $A \setminus C$ tienen un mapeo no controlado, es decir que si $w \in A \setminus C \Rightarrow \psi \circ \varphi(w) \neq w$.

$$P[\boldsymbol{X}_n \neq \psi \circ \varphi(\boldsymbol{X}_n)] = P[\boldsymbol{X}_n \notin C] \leq \varepsilon$$

- Las palabras en C' tiene un largo fijo de l bits.

Definición 1. Longitud mínima de texto binario necesaria para codificar palabras de largo n con nivel ε $L(n;\varepsilon) = \text{mín}\left\{l \geq 0 : \exists C \subset A^n / |C| < 2^l \wedge P(\boldsymbol{X}_n \in C) \geq 1-\varepsilon\right\}$.

Teorema 2. *Teorema de Shanon:*

$$\lim_n \frac{L(n;\varepsilon)}{n} = H(\rho) := -\sum_{a \in A} \rho(a) \log_2 \rho(a)$$

Lema 3. *Propiedad Asintótica de las Particiones.*

Demostración. Se puede asumir $\forall a : \rho(a) > 0$. Si no, redefinimos y excluimos a del diccionario.

Definamos $Y_i = -\log_2 \rho(X_i)$. Estas heredan la condición de iid de las X_i porque dependen cada una de una v.a. distinta (y las X_i son iid). Además, su rango es finito, por lo tanto existen la esperanza y la varianza.

$$\mathbb{E}(Y_i) = -\sum_{a \in A} \rho(a) \log_2 \rho(a) = H(\rho)$$

La varianza existe seguro por tener rango finito, digamos $\mathbb{V}(Y_i) = v$. $\sum_{i=1}^n Y_i = \sum_{i=1}^n -\log_2 \rho(X_i) = -\log_2 \prod_{i=1}^n \rho(X_i)$ pero $\prod_{i=1}^n \rho(X_i) = P(X_1 = x_1; X_2 = x_2; ...; X_n = x_n)$.

$$P\left(\left|\frac{1}{n}\sum_{i=1}^n Y_i - H(\rho)\right| > \delta\right) \leq \delta$$

Podemos decir $\frac{1}{n}\sum_{i=1}^n Y_i = -\frac{1}{n}\log_2 \rho^{\otimes n}(\boldsymbol{X}_n)$. Donde $\rho^{\otimes n}(\boldsymbol{X}_n) = P \circ \boldsymbol{X}_n^{-1}$[1].

$$P\left(\left|-\frac{1}{n}\log_2 \rho^{\otimes n}(\boldsymbol{X}_n) - H(\rho)\right| > \delta\right) \leq \delta$$

Llamemos al conjunto en el intervalo $B_n = \left\{w \in A^n : 2^{-n(H(\rho)+\delta)} \leq \rho^{\otimes n}(w) \leq 2^{-n(H(\rho)-\delta)}\right\}$.

$$P(\boldsymbol{X}_n \in B_n) \geq 1-\delta$$

□

[1]Es decir, $\rho^{\otimes n}(\boldsymbol{X}_n)$ es la distribución de los vectores $\boldsymbol{X}_n$, que como tienen todas las componentes equidistribuidas e independientes tienen una densidad que es un exponente de la densidad de X_1.

Demostración. Teorema de Shanon.

Elijamos $\delta = \varepsilon$ y trabajemos con el B_n obtenido.

$C = B_n$ y este está cubierto por la definición de $L(n;\varepsilon)$. Reescribamos $L(n;\varepsilon)$ en términos de B_n.

$$L(n;\varepsilon) \leq \operatorname{argmin}_l \left\{ |B_n| \leq 2^l \right\}$$

$$1 = \sum_{w \in A^n} \rho^{\otimes n}(w) \geq \sum_{w \in B_n} \rho^{\otimes n}(w)$$

Podemos acotar en la sumatoria el $\rho^{\otimes n}(w)$ usando $B_n = \left\{ w \in A^n : 2^{-n(H(\rho)+\delta)} \leq \rho^{\otimes n}(w) \leq 2^{-n(H(\rho)-\delta)} \right\}$.

$$1 \geq 2^{-n(H(\rho)+\delta)} \cdot \sum_{w \in B_n} 1$$

$$1 \geq |B_n| \, 2^{-n(H(\rho)+\delta)}$$

$$2^{n(H(\rho)+\delta)} \geq |B_n|$$

Volvemos a $L(n;\varepsilon) \leq \operatorname{argmin}_l \left\{ |B_n| \leq 2^l \right\}$

$$\forall n : L(n;\varepsilon) \leq n(H(\rho) + \delta)$$

Como δ es arbitrariamente chico:

$$\limsup_n \frac{L(n;\varepsilon)}{n} \leq \limsup_n \frac{n(H(\rho)+\delta)}{n}$$

$$\limsup_n \frac{L(n;\varepsilon)}{n} \leq H(\rho)$$

Por otra parte, si $l = L(n;\varepsilon)$ cumple la definición y $C \subset A^n / |C| \leq 2^l \wedge P(\boldsymbol{X}_n \in C) \geq 1 - \varepsilon$.

Por la cota del lema

$$w \in B_n : \rho^{\otimes n}(w) \leq 2^{-n(H(\rho)-\delta)}$$

$$\rho^{\otimes n}(w) \, 2^{n(H(\rho)-\delta)} \leq 1$$

$$2^{L(n;\varepsilon)} \geq |C| \geq |C \cap B_n| \geq \sum_{w \in C \cap B_n} 1 \geq \sum_{w \in C \cap B_n} \rho^{\otimes n}(w) \, 2^{n(H(\rho)-\delta)}$$

$$2^{L(n;\varepsilon)} \geq 2^{n(H(\rho)-\delta)} \underbrace{\sum_{w \in C \cap B_n} \rho^{\otimes n}(w)}_{P(\boldsymbol{X}_n \in C \cap B_n)}$$

$$\geq 2^{n(H(\rho)-\delta)} (1 - \varepsilon - \delta)$$

$P(A^n) = 1$, $P(B_n) = 1 - \varepsilon$. Al hacer $P(B_n \cap C)$, estamos reduciendo el tamaño de un conjunto que ya tenía una probabilidad más chica que $1 - \varepsilon$ más aún, en una cantidad δ desconocida.

$$L(n;\varepsilon) \geq \log_2(1 - \varepsilon - \delta) + n(H(\rho) - \delta)$$

$$\begin{aligned}\liminf_{n} \frac{L(n;\varepsilon)}{n} &\geq \liminf_{n} \frac{\log_2(1-\varepsilon-\delta)+n(H(\rho)-\delta)}{n} \\ &\geq H(\rho)\end{aligned}$$

$\square$