SEA $(X_i)_{i=1}^n$ UNA MUESTRA ALEATORIA DE UNA DISTRIBUCIÓN DISCRETA Y DE RANGO $(y_i)_{i=1}^k$ CON PROBABILIDADES RESPECTIVAS $(p_i)_{i=1}^k$.

1. Obtener el EMV para los valores p_i en el caso en que todos ellos sean positivos y en la muestra fueron observados todos los valores del rango de Y.

Si la muestra es $\boldsymbol{x} = (x_1; x_2....)$ entonces $P_{\boldsymbol{X}}(\boldsymbol{x}) = \prod_{i=1}^k p_i^{\#\{j/x_j=y_i\}}$, es decir que obtenemos la probabilidad como la probabilidad de la intersección de los eventos independientes $x_i = y_j$, cada uno de probabilidad conocida. El exponente en $p_i^{\#\{j/x_j=y_i\}}$ se debe a que p_j aparece en el cálculo de la probabilidad de la muestra tantas veces como lo hace y_j.

La verosimilitud evaluada en un parámetro $\boldsymbol{p} = (p_1; p_2; ...; p_k)$ es

$$L_{\boldsymbol{X}}(\boldsymbol{p}) = \prod_{i=1}^k p_i^{\#\{j/x_j=y_i\}}$$

- No es conveniente tomar logaritmo y derivar porque se llega a una optimización por multiplicadores de Lagrange muy trabajosa.

A la expresión $\frac{\#\{j/x_j=y_i\}}{n} = \frac{\sum_{j=1}^n \mathbf{1}_{\{y_i\}}(x_j)}{n}$ la vamos a llamar «frecuencia empírica» y simbolarzarla así: $\frac{\#\{j/x_j=y_i\}}{n} = \hat{p}_i$.

Es evidente que es un buen candidato a ser el estimador de la probabilidad. De hecho, también podemos encontrar este estimador por el método de momentos como la esperanza de cada indicadora (esto siempre a tono de pista, no hay forma de asegurar que los estimadores tengan que ser iguales ni mucho menos).

En síntesis, nuestro estimador para la probabilidad *de toda la muestra* es $\prod_{i=1}^k \hat{p}_i^{n\hat{p}_i} = \prod_{i=1}^k \frac{\#\{j/x_j=y_i\}}{n}$.

Digamos que el estimador del vector de probabilidades que estamos estudiando es $\hat{\boldsymbol{p}} = (\hat{p}_1; \hat{p}_2; ...; \hat{p}_k)$, consideremos la verosimilitud de un estimador cualquiera $\hat{\boldsymbol{\alpha}} = (\hat{\alpha}_1; \hat{\alpha}_2; ...; \hat{\alpha}_k)$.

$$
\begin{aligned}
L_{\boldsymbol{X}}(\hat{\boldsymbol{\alpha}}) &= \prod_{i=1}^{k} \hat{\alpha}_i^{\underbrace{\#\{j/x_j = y_i\}}_{n\hat{p}_i}} \\
&= \prod_{i=1}^{k} \left(\alpha_i \cdot \frac{\hat{p}_i}{\hat{p}_i}\right)^{n\hat{p}_i} \\
&= \left(\prod_{i=1}^{k} \hat{p}_i^{n\hat{p}_i}\right) \cdot \left[\prod_{i=1}^{k} \left(\hat{\alpha}_i \cdot \frac{1}{\hat{p}_i}\right)^{n\hat{p}_i}\right] \\
&= L_{\boldsymbol{X}}(\hat{\boldsymbol{p}}) \cdot \underbrace{\left[\prod_{i=1}^{k} \left(\frac{\hat{\alpha}_i}{\hat{p}_i}\right)^{n\hat{p}_i}\right]}_{A}
\end{aligned}
$$

Esto es válido porque podemos asegurar que todos los elementos aparecieron al menos una vez en la muestra por hipótesis y entonces el estimador nunca es cero: $\forall i : \hat{p}_i > 0$.

- Acá se ve que pasa si algún estimador da 0. Vamos a tener que definir que estimamos la probabilidad como $\hat{p} = 0$ y definir que estos no participan de la productoria, lo cual es sostenible considerando que también tendríamos un exponente 0 en ese caso dado el doble rol de $\hat{p}$ en la definición.
- Lo que desarrollamos hasta ahora no depende de la forma de nuestro estimador, pero encontramos algo interestante: la verosimilitud de todo estimador se puede expresar como un múltiplo de la verosimilitud de nuestro estimador $\hat{\boldsymbol{p}}$ por un factor en función de las probabilidades elegidas, A.

Usemos la desigualdad $x \leq e^{x-1}$ para acotar la productoria A, aplicada factor a factor en todos los factores (manteniendo para cada par de factores en la desigualdad el exponente).

$$
\begin{aligned}
\prod_{i=1}^{k}\left(\underbrace{\frac{\hat{\alpha}_i}{\hat{p}_i}}_{x}\right)^{n\hat{p}_i} &\leq \prod_{i=1}^{k}\left[\underbrace{\exp\left(\frac{\hat{\alpha}_i}{\hat{p}_i}-1\right)}_{e^{x-1}}\right]^{n\hat{p}_i} \\
&\prod_{i=1}^{k}\exp\left[n\hat{p}_i\cdot\left(\frac{\hat{\alpha}_i}{\hat{p}_i}-1\right)\right] \\
&= \prod_{i=1}^{k}\exp\left[(n\hat{\alpha}_i - n\hat{p}_i)\right] \\
&= \exp\left(n\underbrace{\sum_{i=1}^{k}\hat{\alpha}_i}_{1} - n\underbrace{\sum_{i=1}^{k}\hat{p}_i}_{1}\right) \\
&= \exp\left(n-n\right) \\
&= 1
\end{aligned}
$$

Considerando que $\sum p_i = 1$ porque son todas las probabilidades positivas de un espacio discreto y en el caso de $\hat{p}_i$ porque tenemos algo del tipo $\sum_{i\in\Omega}\frac{\#\{j/x_j=y_i\}}{n} = \frac{\#\Omega}{n} = \frac{n}{n} = 1$.

Lo que estamos diciendo es que para **cualquier** estimador[1] que usemos, su verosimilitud es un múltiplo de la verosimilitud de $\hat{\boldsymbol{p}}$y que el factor de esta multiplicidad es menor o igual a 1, por lo tanto $\hat{\boldsymbol{p}}$ es un estimador de máxima verosimilitud.

Además, para $x \neq 1$ sabemos que $x < e^{x-1}$, es decir que la desigualdad empleada es estricta en todo estimador donde $\frac{\hat{\alpha}_i}{\hat{p}_i} \neq 1$, y este se hace 1 sólo para el caso $\hat{\alpha}_i = \hat{p}_i$.

Entonces, $\hat{\boldsymbol{p}}$ es el único estimador de máxima verosimilitud.

1.1. ¿Podría suceder que se observe y_1 cuando el valor de $p_1 = 0$? Si existe una distribución discreta que determina el proceso muestral, sabemos que ningún elemento que tenga probabilidad 0 va a ser observado.

Si lo vemos desde un punto de vista empírico, asignarle probabilidad 0 a un evento observado siempre nos va a dar una muestra de verosimilitud 0, por lo que nunca va a ser un estimador destacado para este criterio.

[1]Siempre y cuando tenga la muy lógica propiedad $\sum_{i=1}^k \hat{\alpha}_i = 1$.