6. Esperanza

Probabilidades y Estadística (M)

María Eugenia Szretter Noste

Departamento de Matemática e
Instituto de Cálculo
Facultad de Ciencias Exactas y Naturales
Universidad de Buenos Aires

Primer cuatrimestre 2020

Ejemplo 6.1 (leonas)

Una leona da a luz entre 1 y 4 cachorros por camada. Sea X la cantidad de crías que tiene una leona en una camada, la función de probabilidad puntual de X está dada por

k	1	2	3	4
$p_X(k)$	0.2	0.3	0.1	0.4

Un grupo de estudio de ecología animal selecciona al azar n partos de leona, y registra lo obtenido. Sean $X_1, X_2, \cdots, X_n$ los tamaños de las camadas observadas. Este grupo está interesado en averiguar la cantidad promedio de leones que nacen por camada, es decir en $\frac{1}{n}\sum_{i=1}^{n} X_i$. Para fijar ideas, toma $n = 30$. Los valores obtenidos en una realización del experimento resultan ser:

1 4 3 2 4 4 4 4 4 3 1 4 4 1 1 4 1 4 3 1 2 4 1 4 2 2 4 2 1 1

Ejemplo 6.1, cont.

$$\frac{1}{n}\sum_{i=1}^{n} X_i = \frac{1}{30}\{1+4+3+\cdots 2+1+1\}$$

$$= \frac{1}{30}\left\{\underbrace{1+\cdots+1}_{n_1}+\underbrace{2+\cdots+2}_{n_2}+\underbrace{3+\cdots+3}_{n_3}+\underbrace{4+\cdots+4}_{n_4}\right\}$$

$$= \frac{1}{30}\{1\cdot n_1+2\cdot n_2+3\cdot n_3+4\cdot n_4\}$$

$$= 1\cdot\frac{n_1}{n}+2\cdot\frac{n_2}{n}+3\cdot\frac{n_3}{n}+4\cdot\frac{n_4}{n} \underset{n\to\infty}{\approx} \sum_{k=1}^{4} k\ p_X(k)$$

$$= \sum_{k\in R_X} k\ p_X(k)$$

6. Motivación

Consideremos una variable aleatoria discreta X tomando los valores $\{k : k \in R_X\}$ y con función de probabilidad puntual $p_X(k)$, de forma tal que $0 \leq p_X(k) \leq 1$ y $\sum_{k \in R_X} p_X(k) = 1$. Sean $X_1, X_2, \cdots, X_n$ n repeticiones independientes de nuestra variable aleatoria. Si denotamos por n_k a la cantidad de veces que observamos el resultado k en las n repeticiones, tenemos que

$$\frac{1}{n}\sum_{i=1}^{n} X_i \;=\; \sum_{k \in R_X} k \frac{n_k}{n} \;.$$

Cuando el número de repeticiones n tiende a ∞, sabemos que n_k/n converge a $p_X(k)$. Tenemos entonces que el *promedio muestral de n repeticiones* de nuestra variable aleatoria converge a $\sum_{k \in R_X} k\, p_X(k)$, como vimos en el ejemplo.

Definición 6.1 (esperanza de X discreta)

Dada una variable aleatoria discreta X tal que $\sum_{k\in R_X} |k|\, p_X(k) < \infty$. Definimos la **esperanza, o valor medio de X** *mediante la fórmula,*

$$E[X] = \sum_{k\in R_X} k\, p_X(k). \tag{1}$$

Requerimos que el valor absoluto de la serie converja para que el valor de la $E(X)$ no cambie por reordenamientos de los k. Cuando al menos una de estas sumas

$$\sum_{k\in R_X,\, k>0} k\, p_X(k) < \infty \quad \text{ó} \quad \sum_{k\in R_X,\, k<0} k\, p_X(k) > -\infty.$$

es finita, la suma (1) está bien definida, aunque puede tomar el valor $\pm\infty$.

Ejemplo 6.1, cont.

Sea X la cantidad de crías que tiene una leona en una camada, la función de probabilidad puntual de X está dada por

k	1	2	3	4
$p_X(k)$	0.2	0.3	0.1	0.4

Entonces,

$$\begin{aligned} E[X] &= \sum_{k \in R_X} k\, p_X(k) = 1 \cdot 0{,}2 + 2 \cdot 0{,}3 + 3 \cdot 0{,}1 + 4 \cdot 0{,}4 \\ &= 0{,}2 + 0{,}6 + 0{,}3 + 1{,}6 = 2{,}7 \end{aligned}$$

Observemos que en este caso, $E(X)$ ¡no está en el rango de X! La esperanza no necesita ser uno de los valores posibles para la variable aleatoria.

Esperanza como centro de masa

El concepto de esperanza es análogo al concepto físico del centro de gravedad de una distribución de masa (o centro de masa). Para la variable X que toma los valores k_i con probabilidad $p_X(k_i)$, imaginamos el eje x como una barra que no tiene masa y sobre él ubicamos en los puntos k_i un peso con masa $p_X(k_i)$ (masa total 1), entonces el punto en el cual al apoyar la barra ésta estaría en equilibrio se conoce como el centro de gravedad.

Ejemplos 6.1, cont.

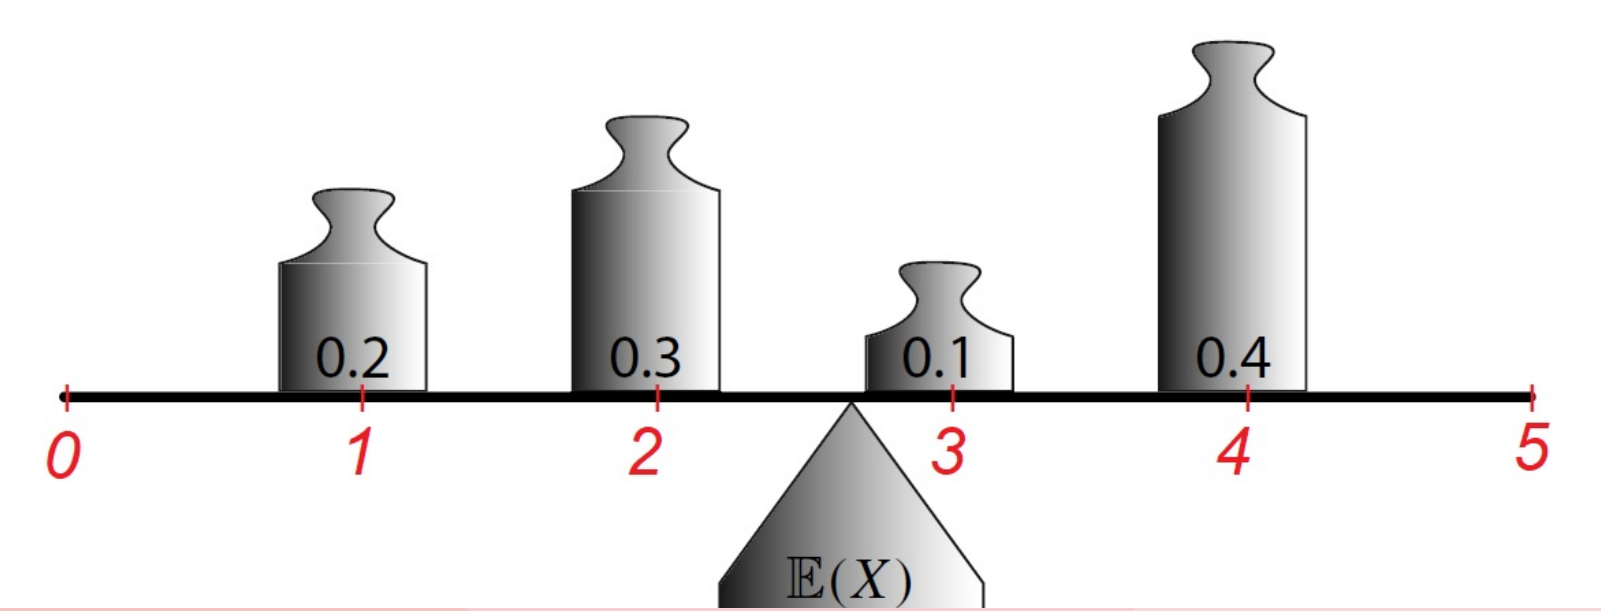

Ejemplo

Ejemplo 6.2 (distribución Bernoulli)

Si $X \sim Be(p)$, entonces $E(X) = 1 \cdot p + 0 \cdot (1 - p) = p$

Ejemplo 6.3 (función indicadora)

Es un caso particular del ejemplo anterior, si $X = I_A$ con $A \in \mathcal{F}$, entonces $E(X) = P(A)$.

Ejemplo 6.4 (distribución geométrica)

Sea $X \sim \mathcal{G}(p)$, es decir, $R_X = \mathbb{N}$ y $p_X(k) = p(1-p)^{k-1}$, para $k \in \mathbb{N}$. Hallemos su esperanza.

$$E[X] = \sum_{k \in R_X} k\ p_X(k) = \sum_{k=1}^{+\infty} kp(1-p)^{k-1}$$

Como $kq^{k-1} = \frac{d}{dq} q^k$, y dentro del radio de convergencia de una serie de potencias podemos intercambiar las operaciones de suma y diferenciación, obtenemos

$$\sum_{k=1}^{+\infty} kq^{k-1} = \sum_{k=1}^{\infty} \frac{d}{dq}[q^k] = \frac{d}{dq}\left[\sum_{k=1}^{\infty} q^k\right] = \frac{d}{dq}\left[\frac{q}{1-q}\right] = \frac{1}{(1-q)^2}, \text{ resulta}$$

$$E(X) = \sum_{k=1}^{+\infty} kp(1-p)^{k-1} = \frac{1}{p}.$$

Por ejemplo, si el 10 % de los items son defectuosos, debemos revisar en promedio 10 items para encontrar uno defectuoso, como podríamos haber anticipado.

Ejemplo 6.5 (v.a. con esperanza infinita)

Sea X variable aleatoria con $R_X = \mathbb{N}$ y $p_X(k) = c\frac{1}{k^2}$ con c para que las puntuales sumen uno. Entonces
$\sum_{k \in R_X} k\ p_X(k) = \sum_{k=1}^{+\infty} kc\frac{1}{k^2} = c\sum_{k=1}^{+\infty} \frac{1}{k} = +\infty$. Podemos aceptar valores $+\infty$ y decir que en este caso, $E[X] = +\infty$.

Ejemplo 6.6 (v.a. sin esperanza)

Sea X variable aleatoria con $R_X = \mathbb{Z} - \{0\}$ y $p_X(k) = a\frac{1}{k^2}$ con a para que las puntuales sumen uno. Entonces
$\sum_{k \in R_X : k>0} k\ p_X(k) = \sum_{k=1}^{+\infty} ka\frac{1}{k^2} = a\sum_{k=1}^{+\infty} \frac{1}{k} = +\infty$ y
$\sum_{k \in R_X : k<0} k\ p_X(k) = \sum_{k=1}^{+\infty}(-k)a\frac{1}{k^2} = -a\sum_{k=1}^{+\infty} \frac{1}{k} = -\infty$. Entonces no podemos definir bien $\sum_{k \in R_X} k\ p_X(k)$ porque la suma no converge absolutamente, y esta distribución no tiene esperanza.

Caso continuo

Definición 6.2

Dada una variable aleatoria continua $X : (\Omega, \mathcal{F}, P) \to \mathbb{R}$ con función de densidad $f_X(x)$, definimos la esperanza de X mediante la fórmula,

$$E[X] = \int_{-\infty}^{\infty} x\, f_X(x)\, dx\,, \tag{2}$$

siempre que $\int_{-\infty}^{\infty} |x|\, f_X(x)\, dx < \infty$.

La condición $\int_{-\infty}^{\infty} |x|\, f_X(x)\, dx < \infty$ es equivalente a la condición discreta $\sum_{k \in R_X} |k|\, p_X(k) < \infty$. Si $f_X(x) = 0$ para $x \leq 0$ y $\int_{-\infty}^{\infty} x\, f_X(x)\, dx = +\infty$ podemos decir que $E[X] = +\infty$, con una conclusión similar para el caso en que $f_X(x) = 0$ para $x \leq 0$, con $E[X] = -\infty$.

Ejemplo 6.7

Si $X \sim \mathcal{U}(0,1)$, $E(X) = \int_0^1 x dx = \frac{1}{2}$

Para entender la definición (2), veamos a las variables (absolutamente) continuas como límites de discretas. Sea X absolutamente continua con $f_X(x) = 0$ para $x \notin [a, b]$. Dado $n \in \mathbb{N}$, dividimos al intervalo $[a, b]$ en n subintervalitos, con extremos en los puntos $\boxed{a + \frac{(b-a)}{n} j}$, con $j = 0, \ldots, n$, y sea $X_n : (\Omega, \mathcal{F}, P) \to \mathbb{R}$ la variable aleatoria discreta dada por

$$X_n(\omega) = \sum_{j=0}^{n-1} \left[a + \frac{(b-a)}{n} j \right] I_{[a+\frac{(b-a)}{n} j, a+\frac{(b-a)}{n}(j+1)]} (X(\omega))$$

O sea,

$$X_n(\omega) = a + \frac{(b-a)}{n} j \qquad \boxed{\text{si } a + \frac{(b-a)}{n} j \leq X(\omega) \leq a + \frac{(b-a)}{n}(j+1)}$$

para $j = 0, \ldots, (n-1)$

$$X_n(\omega) = a + \frac{(b-a)}{n} j \qquad \boxed{\text{si } a + \tfrac{(b-a)}{n} j \leq X(\omega) \leq a + \tfrac{(b-a)}{n}(j+1)}$$

Figura 1: Representación esquemática de la variable aleatoria X con $\Omega = [0, 1]$. La X continua en negro, la discreta X_n que la aproxima en rosa a la izq para $n = 5$, en azul para $n = 11$ a la derecha

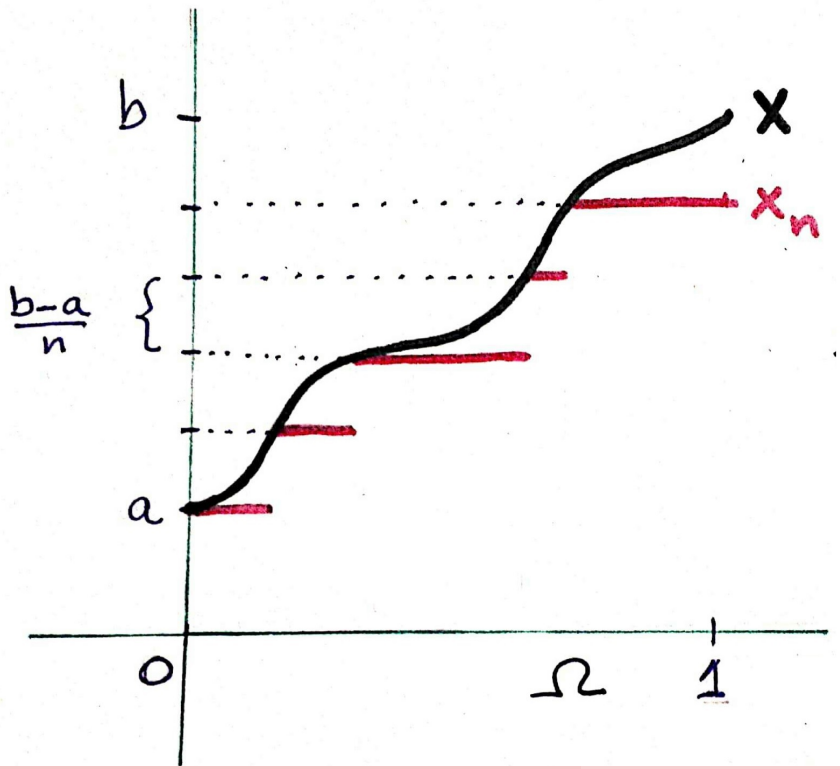

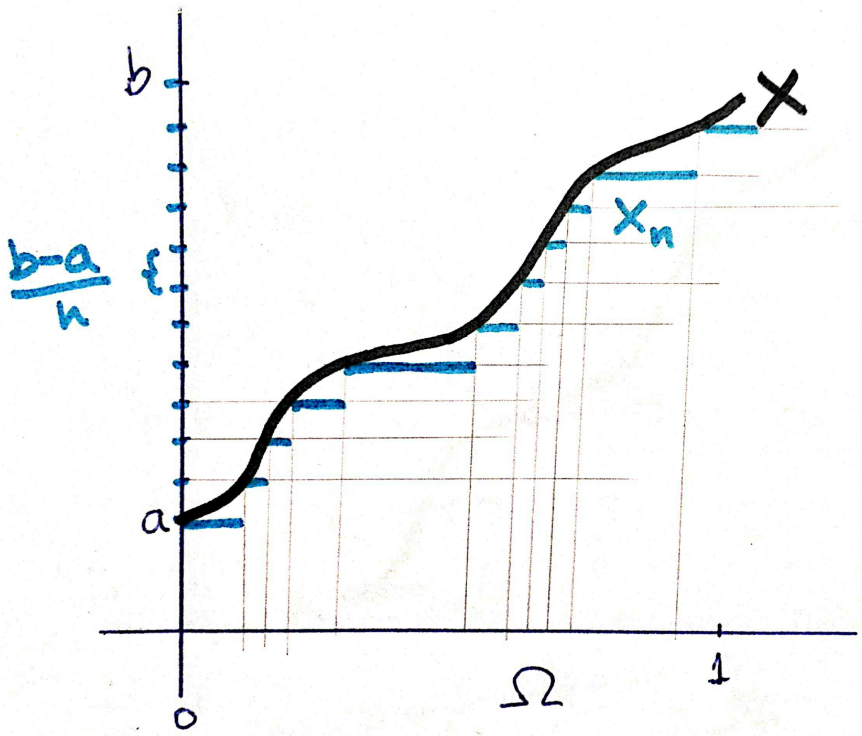

$$X_n(\omega) = a + \frac{(b-a)}{n} j \qquad \boxed{\text{si } a + \tfrac{(b-a)}{n} j \leq X(\omega) \leq a + \tfrac{(b-a)}{n}(j+1)}$$

Entonces,

$$\begin{aligned}
E[X_n] &= \sum_{k \in R_{X_n}} k \; p_{X_n}(k) \\
&= \sum_{j=0}^{n-1} \left(a + \frac{(b-a)}{n} j \right) P\left(X \in \left[a + \frac{(b-a)}{n} j, a + \frac{(b-a)}{n}(j+1) \right] \right) \\
&= \sum_{j=0}^{n-1} \left(a + \frac{(b-a)}{n} j \right) \int_{a+\frac{(b-a)}{n} j}^{a+\frac{(b-a)}{n}(j+1)} f_X(x) dx \\
&\approx \sum_{j=0}^{n-1} \int_{a+\frac{(b-a)}{n} j}^{a+\frac{(b-a)}{n}(j+1)} x f_X(x) dx = \int_a^b x f_X(x) dx
\end{aligned}$$

Funciones de variables o vectores aleatorios

En general $E[g(X)] \neq g\left(E[X]\right)$

Ejemplo 6.8

Sea X que toma los valores -1,0,1 con probabilidades $\frac{1}{3}$ cada uno, tenemos

$$E\left[X\right] = 0$$

Sea $Y = X^2$, toma valores 0 y 1, con probabilidades $\frac{1}{3}$ y $\frac{2}{3}$ respectivamente, tenemos

$$E\left[Y\right] = 0 \cdot \frac{1}{3} + 1 \cdot \frac{2}{3} = \frac{2}{3} \neq 0^2$$

Teorema 6.1

Sea $(X_1, X_2, \ldots, X_n)$ *un vector aleatorio n-dimensional. Sea* $g\colon \mathbb{R}^n \to \mathbb{R}$ *una función boreliana. Consideremos la variable aleatoria* $Y = g(X_1, X_2, \ldots, X_n)$. *Entonces:*

1. *Si* $(X_1, X_2, \ldots, X_n)$ *es discreto y* $\sum_{x_1, x_2, \cdots, x_n} |g(x_1, x_2, \ldots, x_n)| \; p_{X_1 X_2 \ldots X_n}(x_1, x_2, \ldots, x_n) < +\infty$ *entonces*

$$E\Big[g(X_1, \ldots, X_n)\Big] = \sum_{x_1, \cdots, x_n} g(x_1, \ldots, x_n) \; p_{X_1 X_2 \ldots X_n}(x_1, \ldots, x_n)$$

2. *Si* $(X_1, X_2, \ldots, X_n)$ *es continuo y* $\int \ldots \int |g(x_1, \ldots, x_n)| \; f_{X_1 X_2 \ldots X_n}(x_1, \ldots, x_n) dx_1 \; dx_2 \cdots \; dx_n < +\infty$ *entonces*

$$E\Big[g(X_1, \ldots, X_n)\Big] = \int \ldots \int g(x_1, \ldots, x_n) \; f_{X_1 \ldots X_n}(x_1, \ldots, x_n) dx_1 \; \cdots \; dx_n$$

Demostración. (caso discreto).

Llamamos $\tilde{\mathbf{X}} = (X_1, \ldots, X_n)$, $Y = g(X_1, X_2, \ldots, X_n) = g(\tilde{\mathbf{X}})$

$$E(g(\tilde{\mathbf{X}})) = E(Y) = \sum_{y \in R_Y} y p_Y(y)$$

$$= \sum_{y \in R_Y} y P\left(g(\tilde{\mathbf{X}}) = y\right) = \sum_{y \in R_Y} y \left[\sum_{\mathbf{x} \in R_{\tilde{\mathbf{X}}} : g(\mathbf{x}) = y} P(\tilde{\mathbf{X}} = \mathbf{x})\right]$$

$$= \sum_{y \in R_Y} \sum_{\mathbf{x} \in R_{\tilde{\mathbf{X}}} : g(\mathbf{x}) = y} y\, P(\tilde{\mathbf{X}} = \mathbf{x}) = \sum_{y \in R_Y} \sum_{\mathbf{x} \in R_{\tilde{\mathbf{X}}} : g(\mathbf{x}) = y} g(\mathbf{x}) P(\tilde{\mathbf{X}} = \mathbf{x})$$

$$= \sum_{\mathbf{x} \in R_{\tilde{\mathbf{X}}}} g(\mathbf{x}) P(\tilde{\mathbf{X}} = \mathbf{x})$$

El argumento para probar el caso continuo es análogo, pero para que la prueba sea rigurosa hay que usar argumentos de integración que se ven en teoría de la medida. □

Aunque forma parte del resultado anterior, para enfatizarlo, escribamos el enunciado en el caso de $n = 1$.

Teorema 6.2

Sea X una variable aleatoria. Sea $g : \mathbb{R} \to \mathbb{R}$ boreliana y definamos $Y = g(X)$.

1. *Si X es discreta y $\sum_{k \in R_X} |g(k)| \; p_X(k) < +\infty$, entonces*

$$E[Y] = \sum_{k \in R_X} g(k) \, p_X(k)$$

2. *Si X es continua y $\int_{-\infty}^{+\infty} |g(x)| \; f_X(x) dx < +\infty$, entonces*

$$E[Y] = \int_{-\infty}^{+\infty} g(x) \, f_X(x) dx.$$

Ejemplo 6.8, continuación

Sea X que toma los valores -1,0,1 con probabilidades $\frac{1}{3}$ cada uno, tenemos

$$E[X] = 0$$

Sea $Y = X^2 = g(X)$, toma valores 0 y 1, con probabilidades $\frac{1}{3}$ y $\frac{2}{3}$ respectivamente, Habíamos calculado la $E[Y]$ calculando primero la p_Y. Hagámoslo ahora directamente usando la fórmula del Teorema tenemos

$$E[Y] = g(-1) \cdot \frac{1}{3} + g(0) \cdot \frac{1}{3} + g(1) \cdot \frac{1}{3} = \frac{1}{3} + \frac{1}{3} = \frac{2}{3}$$

Ejemplo 3.2, dardos

Se elige un punto al azar sobre un tablero circular de radio siete, y definamos la variable aleatoria D que mide la distancia al centro del tablero. Nos interesa calcular $E(D)$, el valor esperado de la distancia al centro del tablero.

Sea el vector aleatorio (X, Y) con distribución $\mathcal{U}(A)$, la distribución uniforme en $A = \{(x, y) : x^2 + y^2 \leq 49\}$ la bola de radio 7 en $\mathbb{R}^2$. Luego $f_{XY}(x, y) = \dfrac{1}{49\pi} I_A(x, y)$ Entonces, $D = g(X, Y) = \sqrt{X^2 + Y^2}$, y por el Teorema 6.1 tenemos

$$E[D] = E[g(X, Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f_{XY}(x, y) dxdy$$
$$= \int \int_A \sqrt{x^2 + y^2} \frac{1}{49\pi} dxdy$$

Haciendo el cambio a polares, $x = r\cos(\theta)$, $y = r\sin(\theta)$, con jacobiano igual a r. La región A está dada por, $A = \{(r, \theta), 0 \leq r \leq 7, 0 \leq \theta < 2\pi\}$.

Ejemplo 3.2, dardos

$$E[D] = \int\int_A \sqrt{x^2+y^2}\frac{1}{49\pi}dxdy$$
$$= \int_0^{2\pi}\int_0^7 \frac{1}{49\pi}r^2 drd\theta = \frac{1}{49\pi}\ 2\pi\frac{r^3}{3}\Big|_0^7 = \frac{14}{3} = 4{,}66667$$

Otra forma de resolver este ejercicio hubiera sido hallar la densidad de D, completando el vector aleatorio (D, V) con otra variable V de modo que se cumplan las hipótesis del teorema de cambio de variables, calcular la densidad f_{DV}, luego la marginal f_D y finalmente con ella la esperanza de D.

Ejemplo 6.9

Un segmento de longitud uno se corta en dos puntos elegidos al azar. Hallar la longitud esperada del segmento central.
Interpretamos que esta pregunta significa que las ubicaciones de los dos puntos de ruptura son variables aleatorias uniformes independientes U_1 y U_2. Por lo tanto, necesitamos calcular $E\left|U_1 - U_2\right|$. El Teorema 6.1 nos dice que no necesitamos encontrar la función de densidad de $|U_1 - U_2|$ sino que simplemente debemos integrar la función $|u_1 - u_2|$ multiplicada por la densidad conjunta de (U_1, U_2), (que será el producto de las dos densidades marginales puesto que U_1 y U_2 son independientes) , $f_{U_1 U_2}(u_1, u_2) = 1 \cdot I_{[0,1]}(u_1) I_{[0,1]}(u_2)$. Entonces

$$E\left|U_1 - U_2\right| = \int_0^1 \int_0^1 |u_1 - u_2| \, du_1 du_2$$

Dividimos esta integral en dos: sobre el triángulo inferior y superior del $[0,1] \times [0,1]$ dividido por la diagonal $u_1 = u_2$.

Ejemplo 6.9, cont.

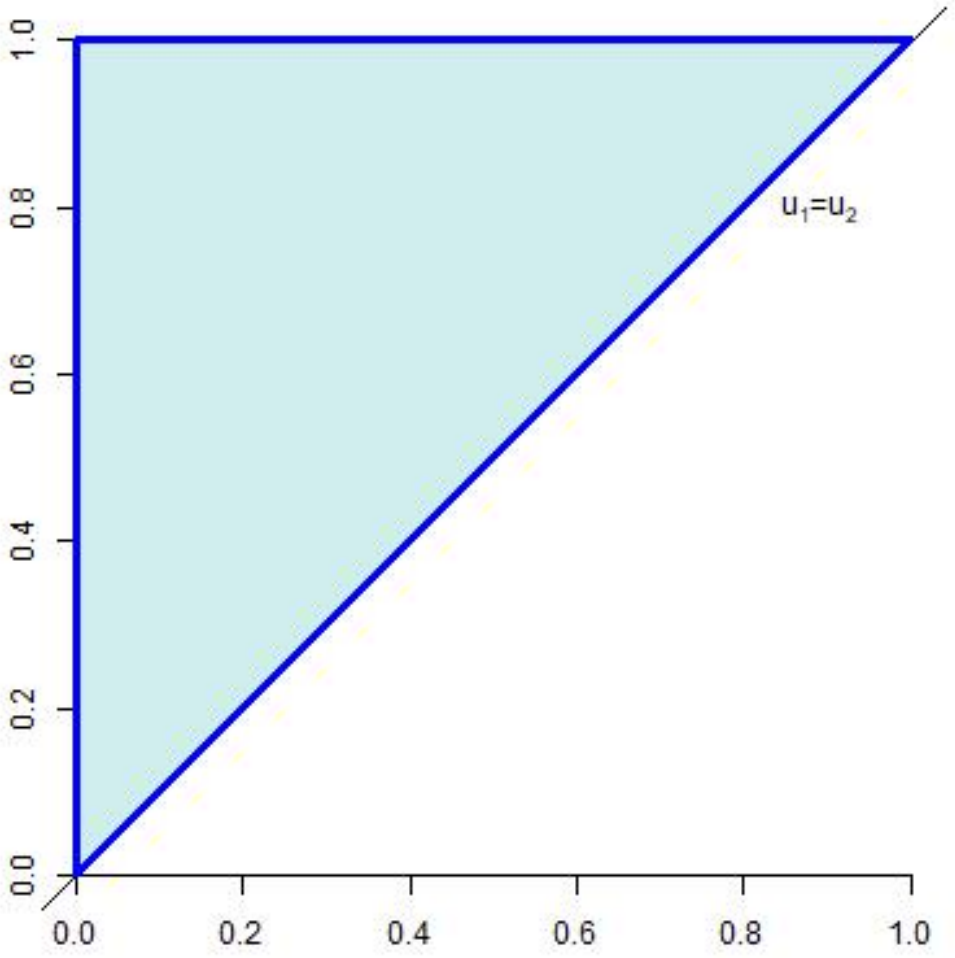

Ejemplo 6.9, cont.

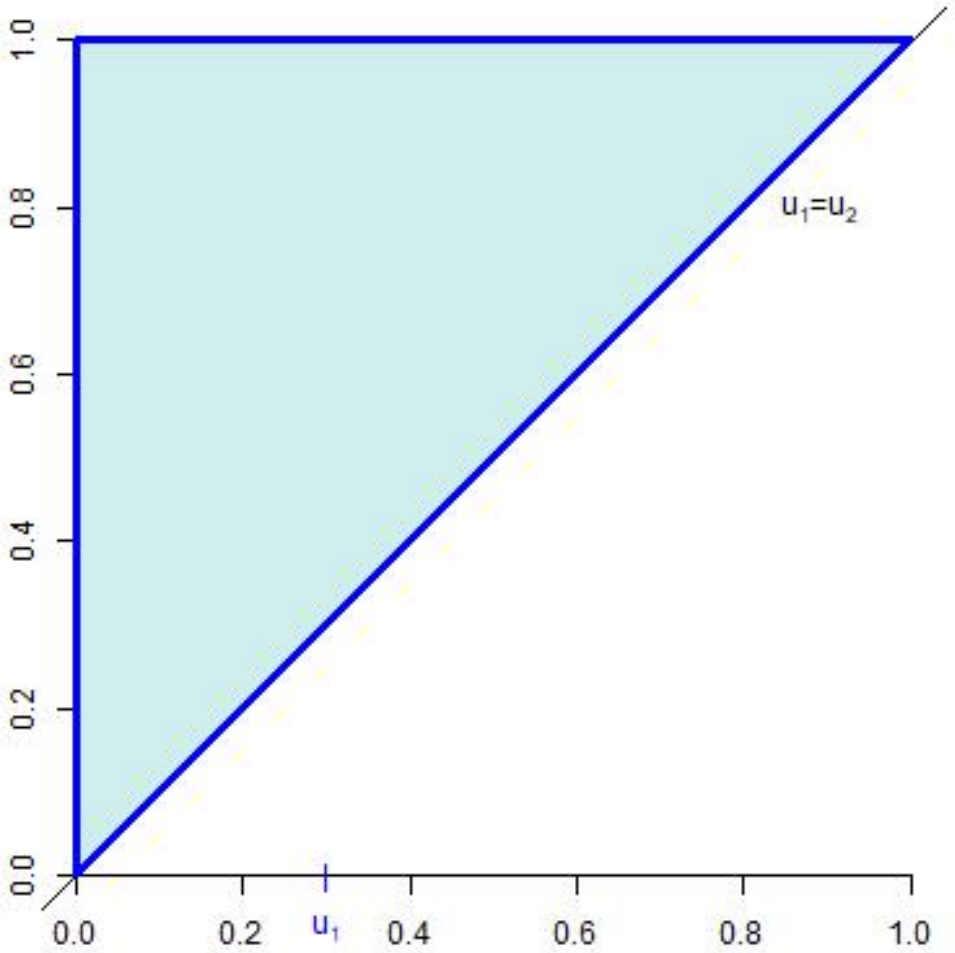

Ejemplo 6.9, cont.

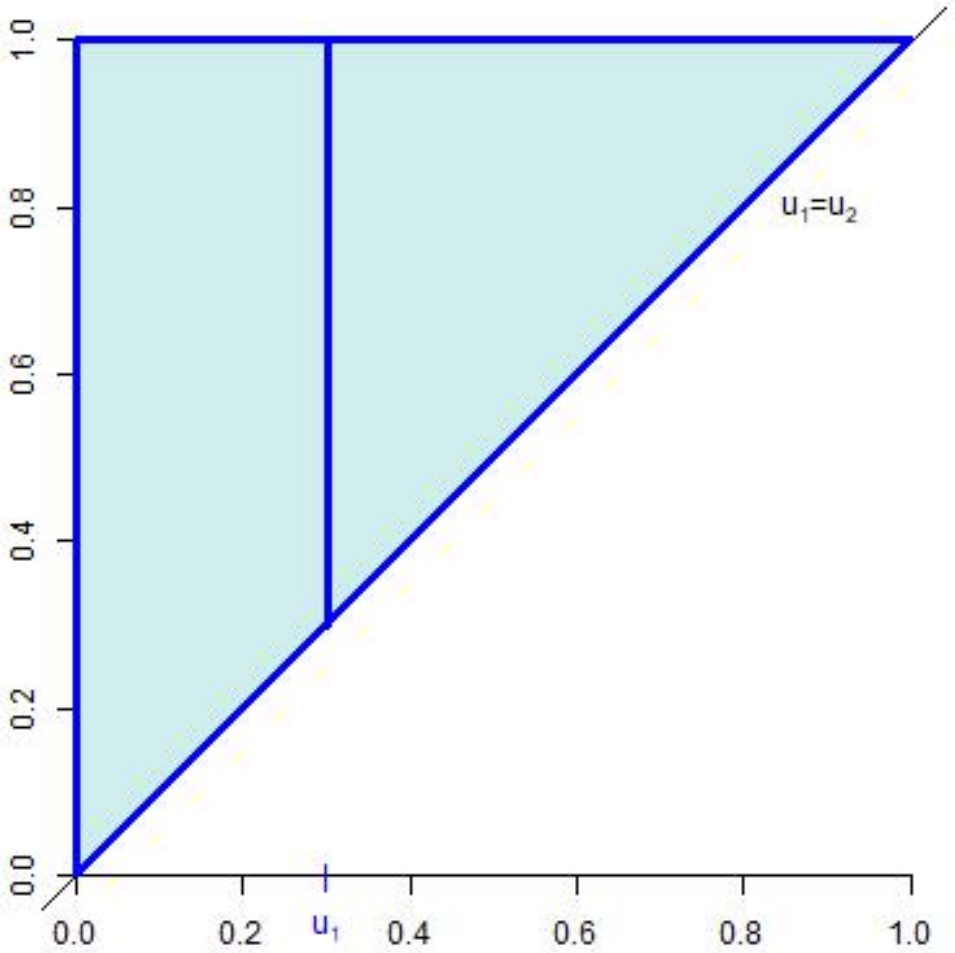

Ejemplo 6.9, cont.

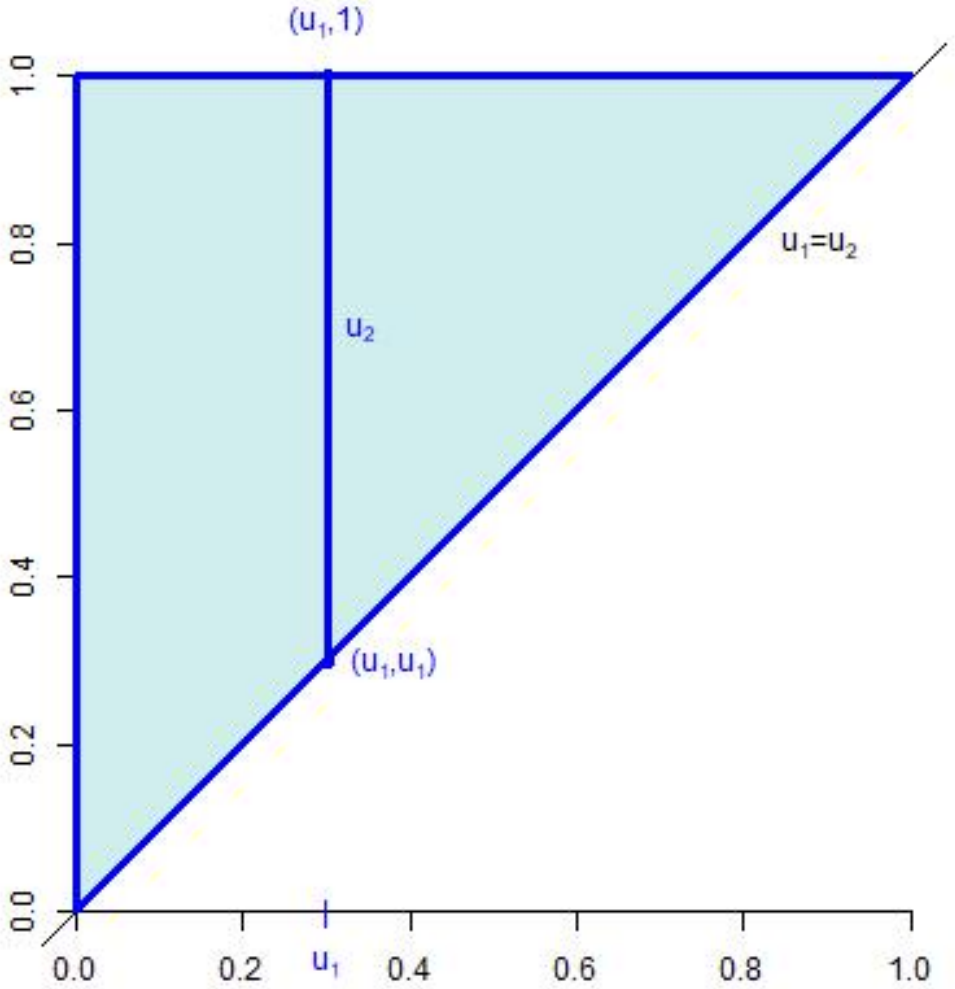

Ejemplo 6.9, cont.

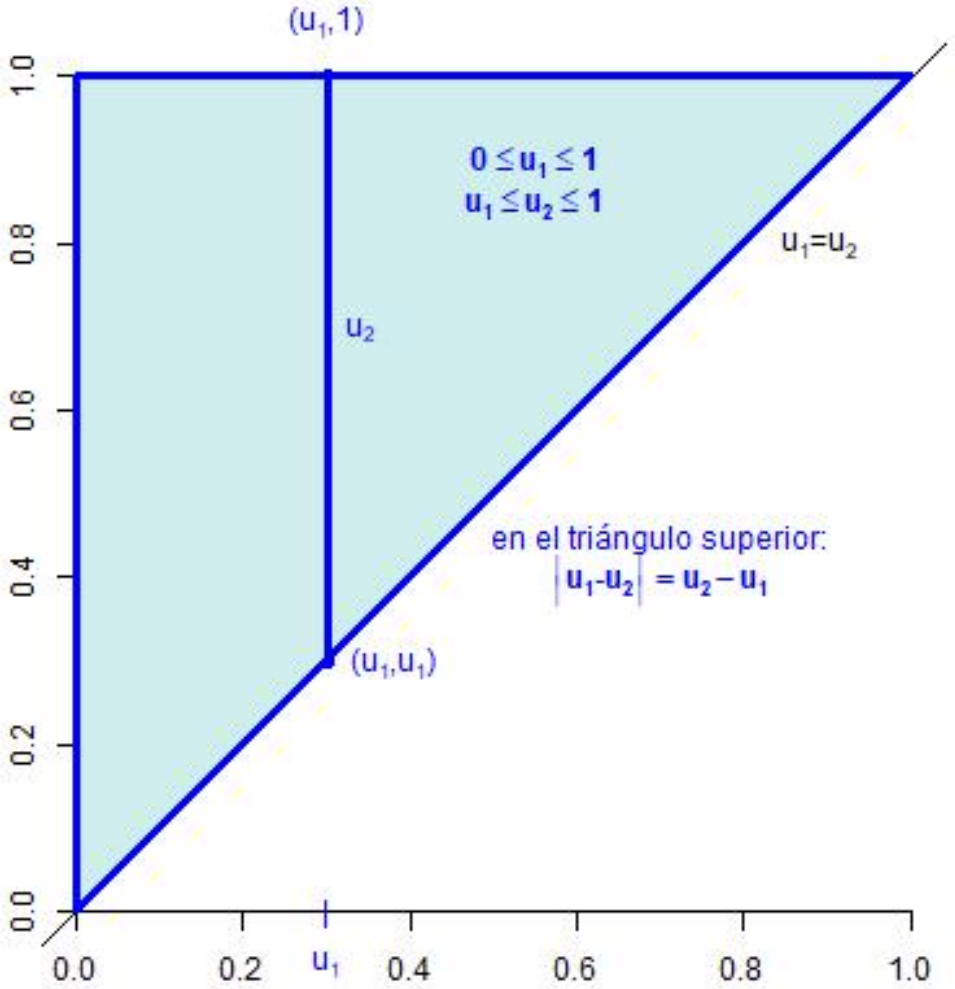

Ejemplo 6.9, cont.

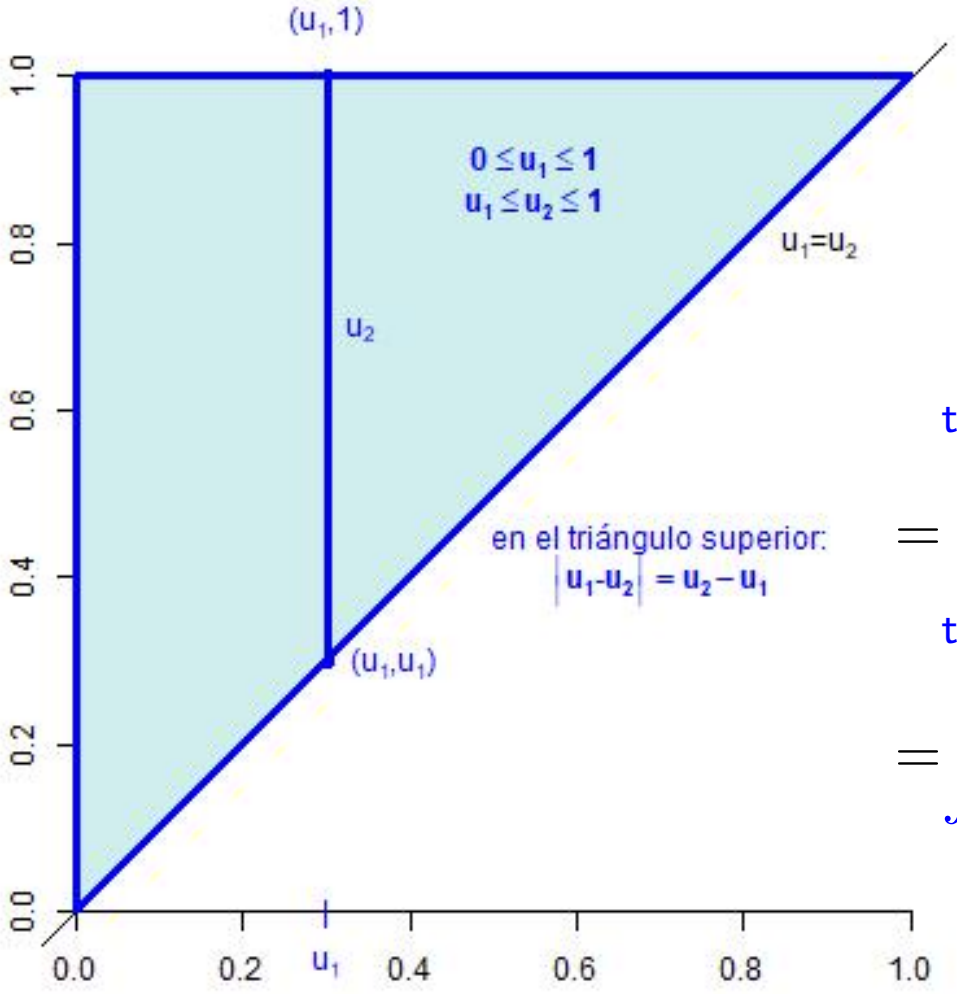

$$\iint_{\text{triang sup}} |u_1 - u_2|\, du_1 du_2$$

$$= \iint_{\text{triang sup}} (u_2 - u_1) du_1 du_2$$

$$= \int_0^1 \int_{u_1}^1 (u_2 - u_1) du_2 du_1$$

Ejemplo 6.9, cont.

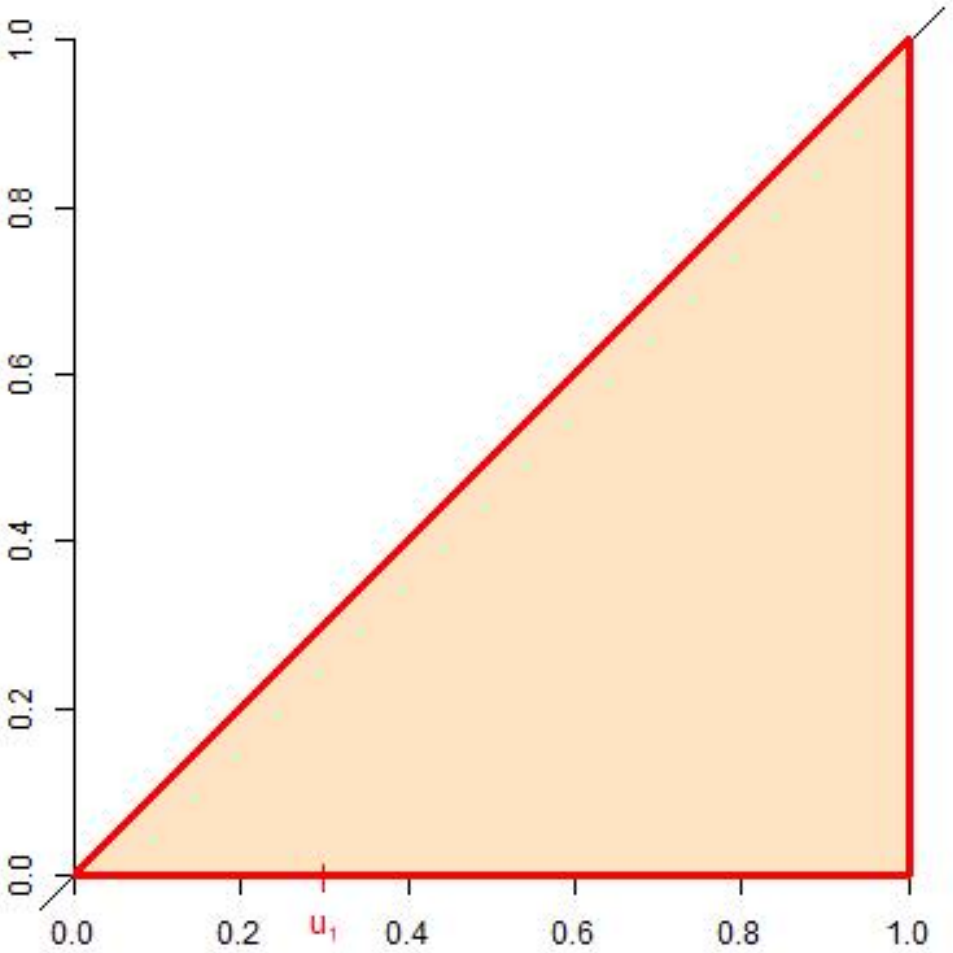

Ejemplo 6.9, cont.

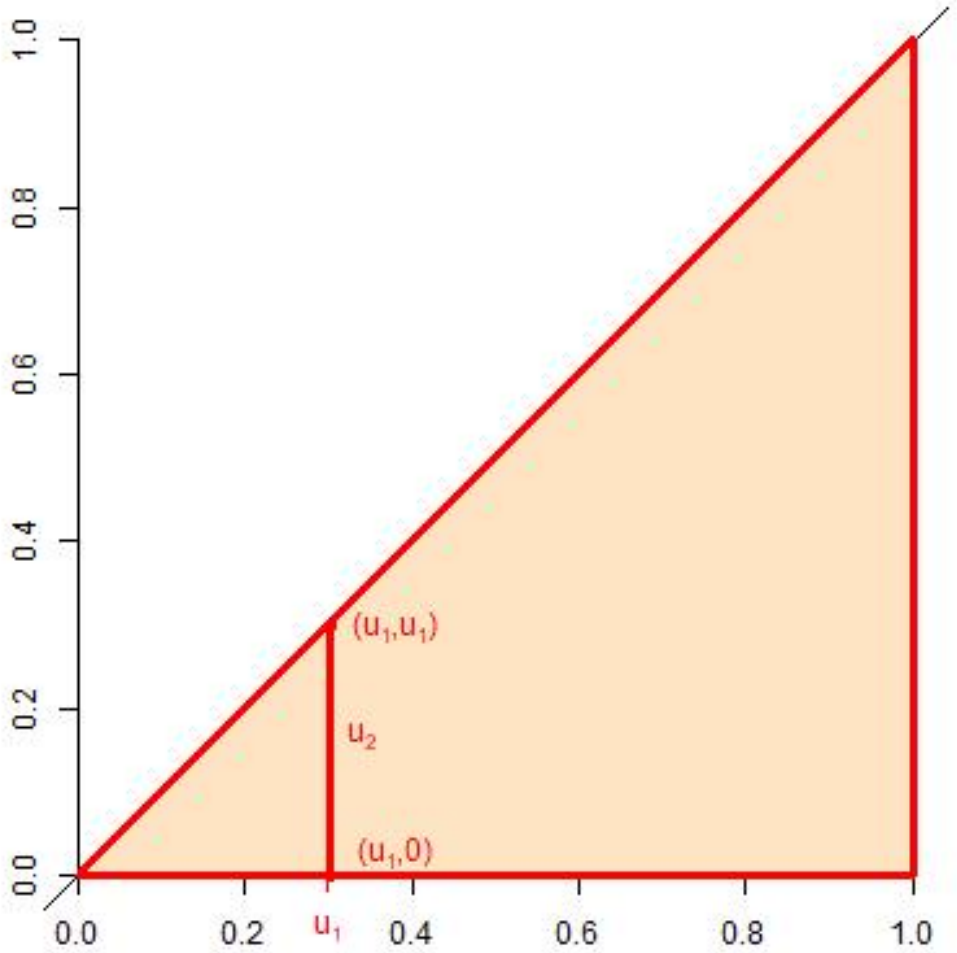

Ejemplo 6.9, cont.

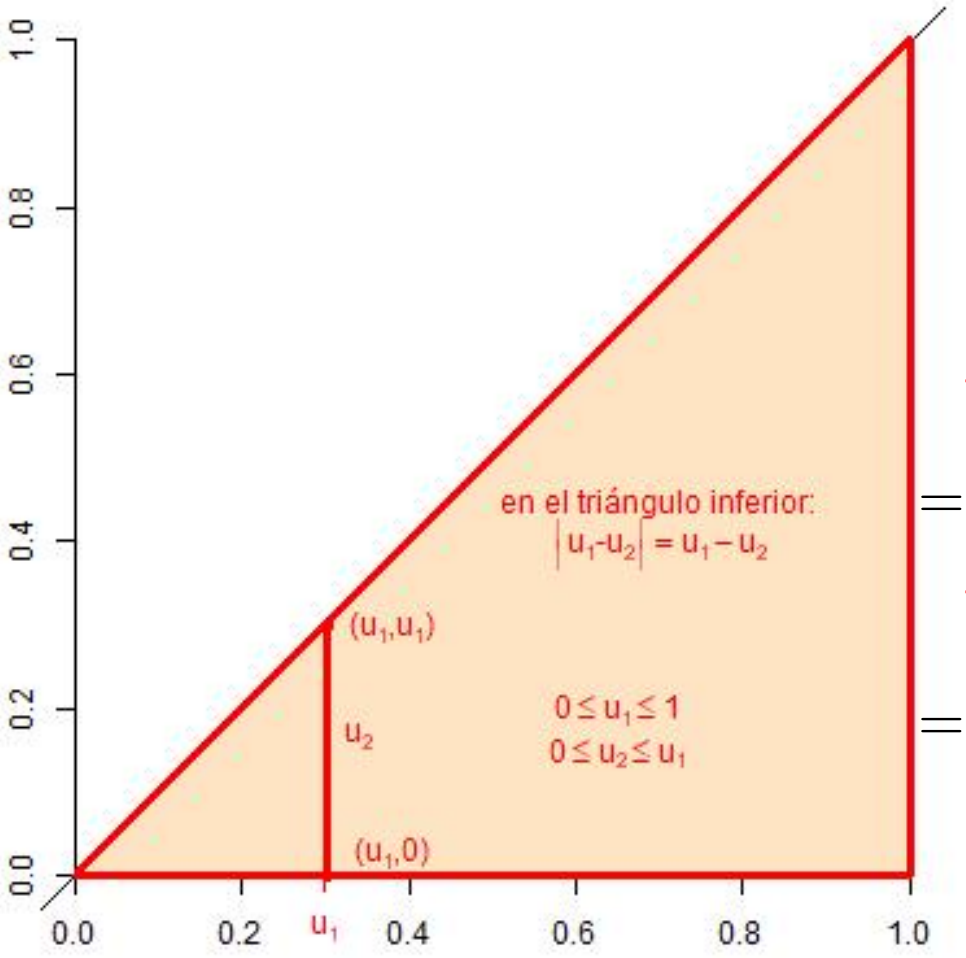

$$\iint_{\text{triang inf}} |u_1 - u_2|\, du_1 du_2$$

$$= \iint_{\text{triang inf}} (u_1 - u_2) du_1 du_2$$

$$= \int_0^1 \int_0^{u_1} (u_1 - u_2) du_2 du_1$$

Ejemplo 6.9, cont.

$$E\,|U_1 - U_2| = \int_0^1 \int_0^{u_1} (u_1 - u_2)\, du_2 du_1 + \int_0^1 \int_{u_1}^1 (u_2 - u_1)\, du_2 du_1$$

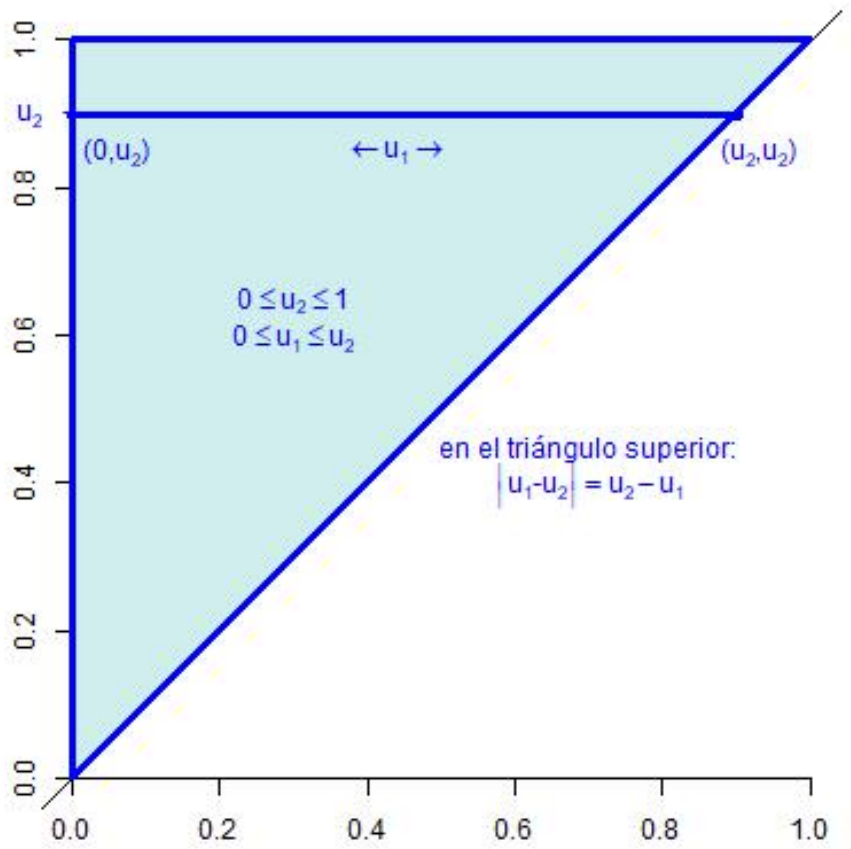

La segunda integral es sobre el triángulo superior, al cual podemos escribir como $\{(u_1, u_2) : 0 \le u_2 \le 1, 0 \le u_1 \le u_2\}$, luego nos da $\int_0^1 \int_0^{u_2} (u_2 - u_1)\, du_1 du_2$ que es igual a la otra integral (la roja) pero con los subíndices cambiados de lugar.

Ejemplo 6.9, cont.

Finalmente

$$E\left|U_1 - U_2\right| = 2\int_0^1 \int_0^{u_1} (u_1 - u_2)\, du_2 du_1 = 2\int_0^1 \left(u_1 u_2 - \frac{u_2^2}{2}\right)\Bigg|_{u_2=0}^{u_2=u_1} du_1$$

$$= \int_0^1 u_1^2 du_1 = \frac{1}{3}$$

Lo cual puede interpretarse desde el punto de vista intuitivo: cada intervalo debiera tener la misma longitud en promedio, o sea $\frac{1}{3}$ cada uno.

Propiedades de la esperanza

Lema 6.3 (linealidad de la esperanza)

Sean X e Y variables aleatorias definidas en $(\Omega, \mathcal{F}, P)$ con esperanza finita. Entonces

a) $E[aX] = aE[X]$, *para todo* $a \in \mathbb{R}$.

b) $E|X+Y| \leq E|X| + E|Y|$.

c) $E[X+Y] = E[X] + E[Y]$.

En general para $X_1, \ldots, X_n$ variables aleatorias con esperanza finita y constantes $a_1, \ldots, a_n \in \mathbb{R}$ tenemos $E\left[\sum_{i=1}^n a_i X_i\right] = \sum_{i=1}^n a_i E[X_i]$.

Demostración. (caso discreto).

a) Sea $Z = aX$, $p_Z(z) = p_X(x)$ si $z = ax$, $R_Z = aR_X$, resulta

$$E[aX] = \sum_{z \in R_Z} z p_Z(z) = \sum_{x \in R_X} a x p_X(x) = a \sum_{x \in R_X} x p_X(x) = aE[X].$$

Demostración. (caso discreto).

Para el b), sea $Z = X + Y$.

$$E\,|Z| = \sum_{z \in R_Z} |z| p_Z(z) = \sum_{z \in R_Z} |z| \sum_{\substack{x \in R_X,\, y \in R_Y \\ x+y=z}} p_{XY}(x,y)$$

$$= \sum_{z \in R_Z} \sum_{\substack{x \in R_X,\, y \in R_Y \\ x+y=z}} |x+y| p_{XY}(x,y) = \sum_{x \in R_X} \sum_{y \in R_Y} |x+y| p_{XY}(x,y)$$

$$\leq \sum_{x \in R_X} \sum_{y \in R_Y} (|x| + |y|) p_{XY}(x,y)$$

$$= \sum_{x \in R_X} \sum_{y \in R_Y} |x| p_{XY}(x,y) + \sum_{x \in R_X} \sum_{y \in R_Y} |y| p_{XY}(x,y)$$

$$= \sum_{x \in R_X} |x| \underbrace{\sum_{y \in R_Y} p_{XY}(x,y)}_{p_X(x)} + \sum_{y \in R_Y} |y| \underbrace{\sum_{x \in R_X} p_{XY}(x,y)}_{p_Y(y)} = E\,|X| + E\,|Y|$$

$\square$

Demostración.

Los cambios de orden de suma están justificados porque las series convergen absolutamente. Luego, el ítem b) prueba además que la esperanza de $X + Y$ es finita, por serlo la del $|X + Y|$.
La prueba de c) es la misma cuenta que el ítem b), sin usar las barras de módulo y con una igualdad en el lugar en que la prueba del ítem b) lleva un $\leq$.
Los items a) y c) dan la linealidad de la esperanza. $\square$

El Lema 6.3, es decir, la linealidad de la esperanza, es una propiedad muy útil. Permite, por ejemplo, calcular la esperanza de la distribución binomial y de la binomial negativa de forma sencilla.

Propiedades de la esperanza

Lema 6.4 (monotonía de la esperanza)

Sean X e Y variables aleatorias definidas en $(\Omega, \mathcal{F}, P)$ con esperanza finita. Entonces si $X \leq Y$, es decir, $X(\omega) \leq Y(\omega)$ $\forall \omega \in \Omega$, luego $E[X] \leq E[Y]$.

Demostración. (caso discreto).

$X \leq Y \Leftrightarrow 0 \leq Y - X = Z$. Como $R_Z \subset \mathbb{R}_{\geq 0}$, resulta $E[Z] \geq 0$.

$E[Z] = E[Y - X] \underbrace{=}_{\text{linealidad}} E[Y] - E[X] \geq 0, \Leftrightarrow E[Y] \geq E[X]$. □

Lema 6.5 (esperanza de una constante)

Sean $X = a$ con probabilidad uno, es decir, sea X una variable aleatoria constante, entonces $E[X] = a$.

Demostración.

$p_X(a) = 1$, luego $E[X] = a \cdot p_X(a) = a$ □

Propiedades de la esperanza

Lema 6.6 (módulo)

$|E(X)| \leq E(|X|)$

Demostración.

(caso continuo)

$$|E(X)| = \left| \int x f_X(x) dx \right| \leq \int |x| f_X(x) dx = E(|X|),$$

donde la última igualdad es válida por el Teorema 6.1. □

Propiedades de la esperanza

Lema 6.7

Si $X \geq 0$ *y* $E[X] = 0$ *entonces* $P(X = 0) = 1$.

Demostración.

Para cada $n \in \mathbb{N}$, definimos la v.a. $Y_n(\omega) = \frac{1}{n} I_{\left[\frac{1}{n}, +\infty\right)}(X(\omega))$, entonces $Y_n \leq X$. Luego, como Y_n es discreta, tenemos la igualdad

$$E(Y_n) = \frac{1}{n} P\left(X \geq \frac{1}{n}\right) \underbrace{\leq}_{\text{monotonía de E}} E(X) = 0.$$

Luego, $P\left(X \geq \frac{1}{n}\right) = 0$ para todo $n \in \mathbb{N}$ y como la sucesión creciente de eventos $\left\{X \geq \frac{1}{n}\right\}$ converge a $\{X > 0\}$, es decir, $\bigcup_{n \geq 1} \left\{X \geq \frac{1}{n}\right\} = \{X > 0\}$, por la monotonía de la probabilidad tenemos que $\lim_{n \to +\infty} P\left(X \geq \frac{1}{n}\right) = P(X > 0) = 0$. □

Propiedades de la esperanza

En general no es cierto que si X e Y son variables aleatorias con esperanza finita ello implique que la $E\left|XY\right|$ también lo sea. Esto sí ocurre en el caso en el que sean independientes, donde además se verifica la siguiente propiedad.

Lema 6.8 (esperanza de variables independientes)

Sean X e Y variables aleatorias independientes con esperanza finita. Entonces la $E\left|XY\right|$ también es finita y vale que

1. $E[XY] = E[X]E[Y]$.
2. *Además* $E[g(X)h(Y)] = E[g(X)]E[h(Y)]$ *para* $g, h : \mathbb{R} \to \mathbb{R}$ *borelianas, y tales que* $E\left|g(X)\right|$, $E\left|h(Y)\right|$ *sean finitas.*

Propiedades de la esperanza

Demostración.

1) (caso continuo) Usamos el Teorema 6.1 primero para $g(X,Y) = |XY|$, para que probemos que esta esperanza existe.

$$E[|XY|] = E[g(X,Y)] = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} g(x,y) f_{XY}(x,y)dxdy$$

$$= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} |xy|\, f_X(x) f_Y(y)dxdy = \left[\int_{-\infty}^{\infty} |x|\, f_X(x)dx\right]\left[\int_{-\infty}^{\infty} |y|\, f_Y(y)dy\right]$$

$$= E[|X|]E[|Y|] < +\infty$$

Ahora, usando el mismo Teorema 6.1 para $g(X,Y) = XY$ y repitiendo los pasos de la cuenta anterior probamos 1). □

Propiedades de la esperanza

Demostración.

2) Por el Lema 5.5 (la independencia de variables o vectores aleatorios se mantiene por transformaciones), resultan $g(X)$ y $h(Y)$ independientes, luego, por 1) vale 2). $\square$

Propiedades de la esperanza

Lema 6.9 (relación con la función de distribución)

Sea X una variable con esperanza finita, entonces

$$E(X) = \int_0^{+\infty} (1 - F_X(x))\, dx - \int_{-\infty}^{0} F_X(x) dx \tag{3}$$

Observemos que en el caso en el que $X \geq 0$, la ecuación (3) queda

$$\boxed{E(X) = \int_0^{+\infty} (1 - F_X(x))\, dx}$$

y da el área comprendida entre la recta horizontal $y = 1$ y el gráfico de F_X, a la derecha del eje y.

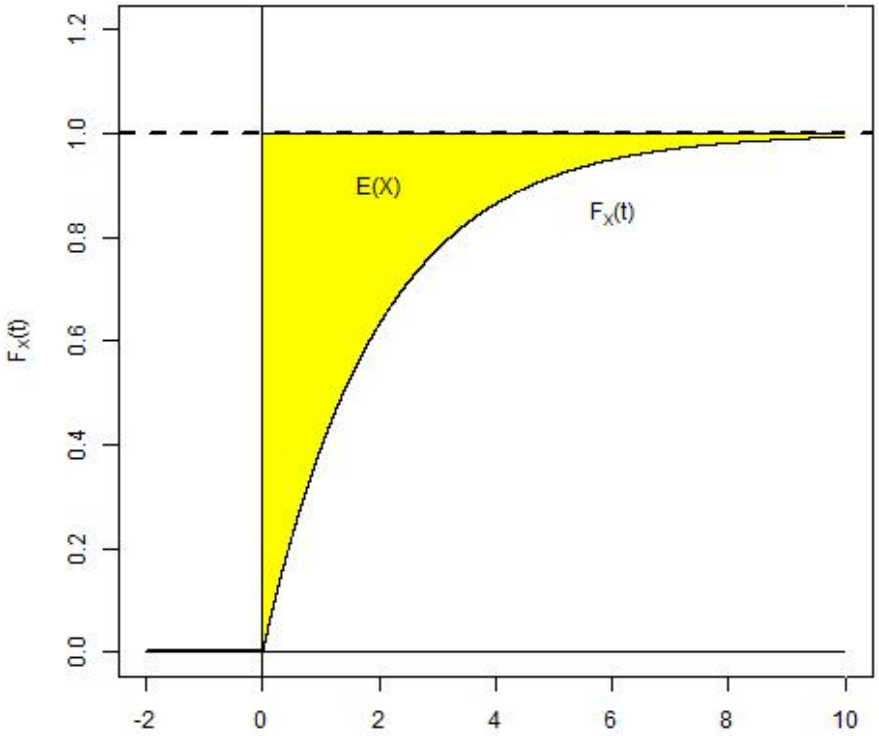

$$E(X) = \int_{-\infty}^{+\infty} x f_X(x)\,dx = \int_0^{+\infty} x f_X(x)\,dx + \int_{-\infty}^{0} x f_X(x)\,dx$$

$$= \int_0^{+\infty} \int_0^{x} dy\, f_X(x)\,dx + \int_{-\infty}^{0} -\int_x^0 dy\, f_X(x)\,dx$$

$$= \underset{A}{\iint} f_X(x)\,dy\,dx + \underset{B}{\iint} f_X(x)\,dy\,dx$$

Cambiamos el orden de integración (Región tipo 1 a tipo 2)

$$\iint_A f_X(x)\,dx\,dy = \int_0^{+\infty}\int_y^{+\infty} f_X(x)\,dx\,dy$$

Cambiamos el orden de integración (tipo I $\leftrightarrow$ tipo II)

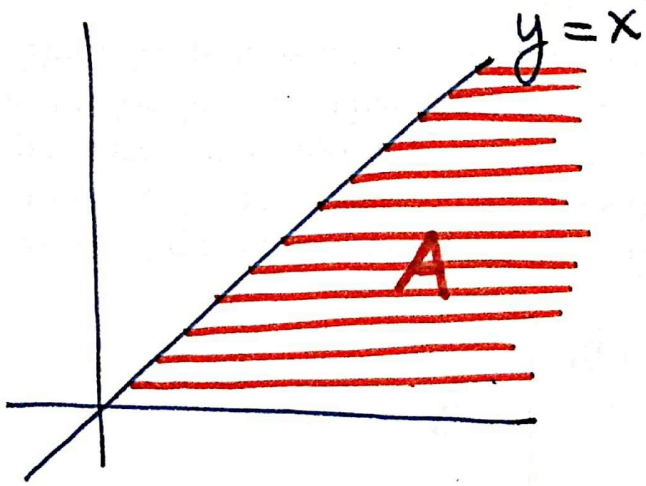

$$A = \left\{ (x,y) : \begin{array}{l} 0 < y < x \\ 0 < x \end{array} \right\}$$

$$= \left\{ (x,y) : \begin{array}{l} y > 0 \\ x > y \end{array} \right\}$$

$$= \int_0^{+\infty} F_X(x)\Big|_{x=y}^{x\to+\infty} dy = \int_0^{+\infty} \left[1 - F_X(y)\right] dy$$

$$\iint_B f_X(x)\,dx\,dy = \int_{-\infty}^{0}\int_{-\infty}^{y} f_X(x)\,dx\,dy$$

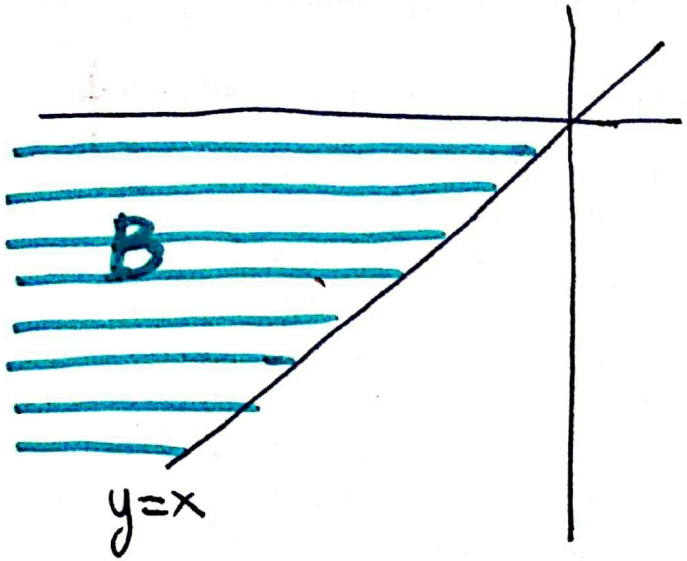

$$B = \{(x,y) : 0 > x,\ x < y < 0\}$$
$$= \left\{(x,y) : \begin{array}{l} y < 0 \\ x < y \end{array}\right\}$$

$$= \int_{-\infty}^{0} F_X(x)\Big|_{x\to-\infty}^{x=y} dy = \int_{-\infty}^{0} F_X(y)\,dy$$

Luego $E(X) = \int_0^{+\infty} [1 - F_X(y)]\,dy - \int_{-\infty}^{0} F_X(y)\,dy$

Demostración.

Caso discreto: sólo lo probamos en el caso en que $X \geq 0$ y además podemos escribir su rango $R_X = \{x_0, x_1, x_2, \ldots\}$ con $x_0 = 0$ y $x_{i-1} < x_i$ para todo $i \geq 1$. Como $p_X(x_i) = F_X(x_i) - F_X(x_{i-1})$, tenemos

$$
\begin{aligned}
E[X] &= \sum_{i=1}^{\infty} x_i p_X(x_i) = \sum_{i=1}^{\infty} x_i \left(F_X(x_i) - F_X(x_{i-1})\right) \\
&= \sum_{i=1}^{\infty} \left[\sum_{j=1}^{i} (x_j - x_{j-1})\right] \left(F_X(x_i) - F_X(x_{i-1})\right) \quad \text{(cambiamos orden)} \\
&= \sum_{j=1}^{\infty} \sum_{i=j}^{\infty} (x_j - x_{j-1}) \left(F_X(x_i) - F_X(x_{i-1})\right) \quad \text{(telescópica)} \\
&= \sum_{j=1}^{\infty} (x_j - x_{j-1}) \left(1 - F_X(x_{j-1})\right) = \int_0^{\infty} (1 - F_X(x)) dx
\end{aligned}
$$

Si 0 no está en el rango, tendremos $F_X(0) = 0$ y exactamente la misma cuenta vale. Cuando X toma valores negativos es análogo al continuo. $\square$

Figura 2: Las figuras (copiadas del apunte de Pablo Ferrari) muestran dos maneras de expresar $\int_0^\infty (1 - F(x))dx$ en el caso discreto. A la izquierda $\sum_{i\geq 1} x_i \left(F\left(x_i\right) - F\left(x_{i-1}\right)\right)$ y a la derecha $\sum_{j\geq 1} \left(x_j - x_{j-1}\right)\left(1 - F\left(x_{j-1}\right)\right)$

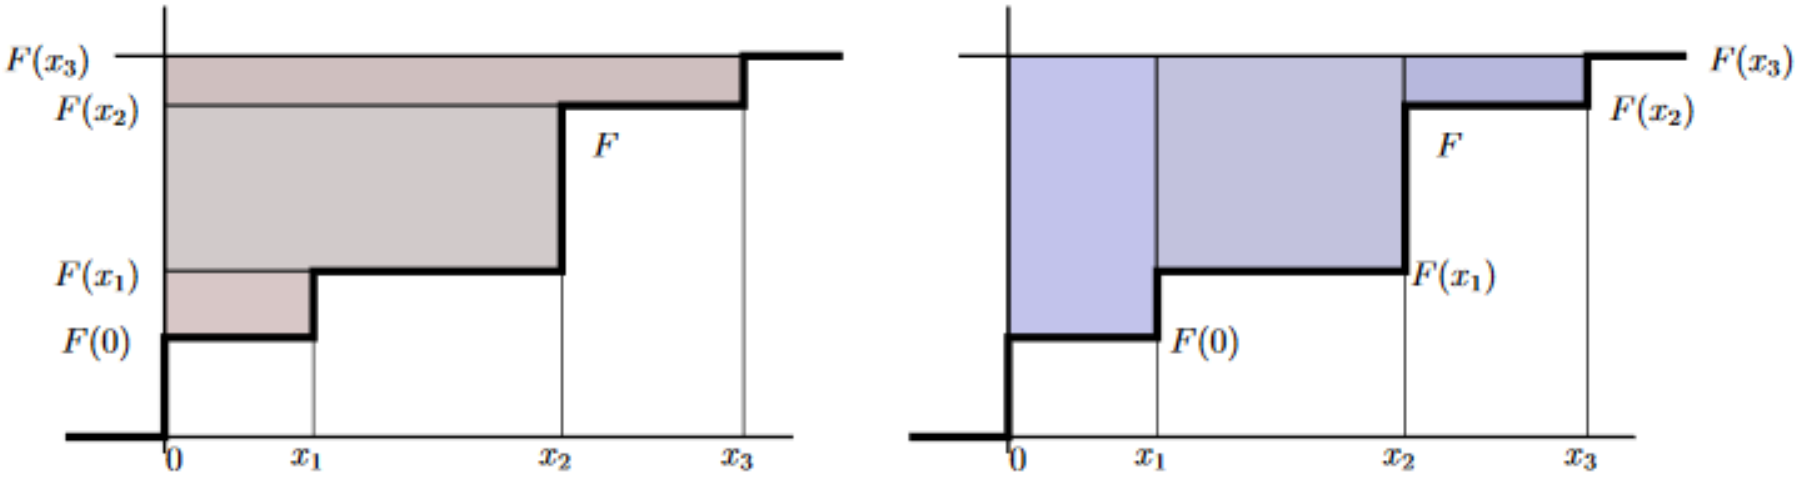

Otra interpretación de la esperanza

Consideremos una variable aleatoria X discreta tomando valores $\{x_1, x_2, \cdots, x_m\}$. Suponga que tenemos que poder resumir en un único numero a la variable aleatoria. Buscamos entonces la "mejor" constante a que "resuma" o "aproxime" a nuestra variable aleatoria. ¿Qué quiere decir mejor aproxime? ¿Cómo comparamos diferentes valores de a?
Vamos a considerar una función de pérdida, que mida cuanto *pagamos* al reemplazar la variable aleatoria X por la constante a. Varias son las funciones de pérdida que pueden ser consideradas en probabilidades y estadística, pero una muy habitual es la llamada pérdida cuadrática, según la cual el precio que pago al aproximar a X por a cuando $X = x_i$ esta dado por $(x_i - a)^2$. Ahora bien, esta pérdida debemos pesarla considerando la frecuencia del valor x_i. Tenemos entonces que el precio que pagamos al aproximar a la variable aleatoria por la constante a está dado por

$$H(a) \;=\; E[(X-a)^2] \;=\; \sum_{i=1}^{m} (x_i - a)^2 \, p_X(x_i) \,.$$

$$H(a) \;=\; E[(X-a)^2] \;=\; \sum_{i=1}^{m}(x_i-a)^2\; p_X(x_i)\;.$$

Buscamos entonces el valor de a que minimiza la función $H(a)$.
Un rápido análisis de la función permite identificar que esta se minimiza cuando $H'(a)=0$.

$$H'(a) = \sum_{i=1}^{m} -2(x_i-a)\; p_X(x_i)\;,$$

por lo tanto, H se minimiza en

$$a \;=\; \sum_{i=1}^{m} x_i\; p_X(x_i)\;.$$

Tenemos así que $a = E[X]$ es la constante que mejor aproxima a nuestra variable aleatoria X.

Varianza

Acabamos de mostrar que la esperanza es la mejor constante para aproximar a nuestra variable aleatoria. Ahora vamos a querer medir cuál es el precio que pagamos al hacer esta aproximacíón. Es decir, queremos calcular cuanto vale la función H en $a = E[X]$.

Definición 6.3 (varianza)

Dada una variable aleatoria X con esperanza μ_X, definimos su **varianza** *que notaremos $V(X)$ ó $\mathrm{Var}(X)$ o también σ_X^2 mediante la fórmula*

$$V(X) = E\Big[\Big(X - \mu_X\Big)^2\Big] .$$

La varianza de la variable aleatoria mide cuán dispersa está la variable aleatoria alrededor de su esperanza. Es decir, cuanto más dispersa esté, mayor será el precio que pagaremos al reemplazarla por una constante (peor resumen estaremos haciendo de la variable cuanto menos concentrada esté).

Propiedades de la varianza

Propiedad V.1

$V(X) \geq 0$ y además $V(X) = 0$ si y sólo si la variable aleatoria es constante $X = \mu_X$ con probabilidad 1, o sea, $P(X = \mu_X) = 1$.

Demostración.

Es consecuencia del Lema 6.7 □

Propiedades de la varianza

La siguiente propiedad, da una fórmula alternativa para computar la varianza de una variable aleatoria.

Propiedad V.2

Sea X una variable aleatoria con $\mu_X = E(X)$, entonces vale que

$$V(X) \;=\; E\left[X^2\right] - \mu_X^2 \,.$$

Demostración.

$$\begin{aligned} V(X) &= E\left[(X-\mu_X)^2\right] \\ &= E\left(X^2 - 2\mu_X X + \mu_X^2\right) \end{aligned}$$

Por la linealidad de la esperanza, resulta

$$\begin{aligned} V(X) &= E\left(X^2\right) - 2\mu_X E(X) + \mu_X^2 \\ &= E\left(X^2\right) - 2\mu_X^2 + \mu_X^2 \\ &= E\left(X^2\right) - \mu_X^2 \end{aligned}$$

Propiedades de la varianza

Propiedad V.3 (cambios de escala)

Dados a y b números reales, tenemos que

$$V(a+bX) \;=\; b^2 V(X)\,.$$

Demostración.

Llamemos $Y = a + bX$. Como $E(Y) = a + bE(X)$

$$\begin{aligned} E\left[(Y-E(Y))^2\right] &= E\left\{[a+bX-a-bE(X)]^2\right\} \\ &= E\left\{b^2[X-E(X)]^2\right\} \\ &= b^2 E\left\{[X-E(X)]^2\right\} = b^2 V(X) \end{aligned}$$

□

Desvío estándar

Definición 6.4 (desvío estándar)

Dada una variable aleatoria X, definimos el **desvío estándar de X** *como la raíz cuadrada de su varianza:*

$$DS(X) = \sqrt{V(X)}\,.$$

Lo notaremos también σ_X.

Por la Propiedad V.3 (cambio de escala) el desvío estándar se transforma de manera natural: si a y b son números reales, e $Y = a + bX$ resulta: $\sigma_Y = |b|\,\sigma_X$. Luego, si las unidades de medida cambiaran de metros a centímetros, por ejemplo, o sea $Y = 100X$ (X es una medida en metros, Y es la misma medida en cm.) el desvío estándar se multiplicaría por 100, $\sigma_Y = 100\sigma_X$.

Ejemplo: dos variables discretas comparables

X variable discreta con $R_X = \{-4, -3, \ldots, 3, 4\}$

k	-4	-3	-2	-1	0	1	2	3	4
$p_X(k)$	0.20	0.17	0.08	0.04	0.01	0.04	0.08	0.17	0.20

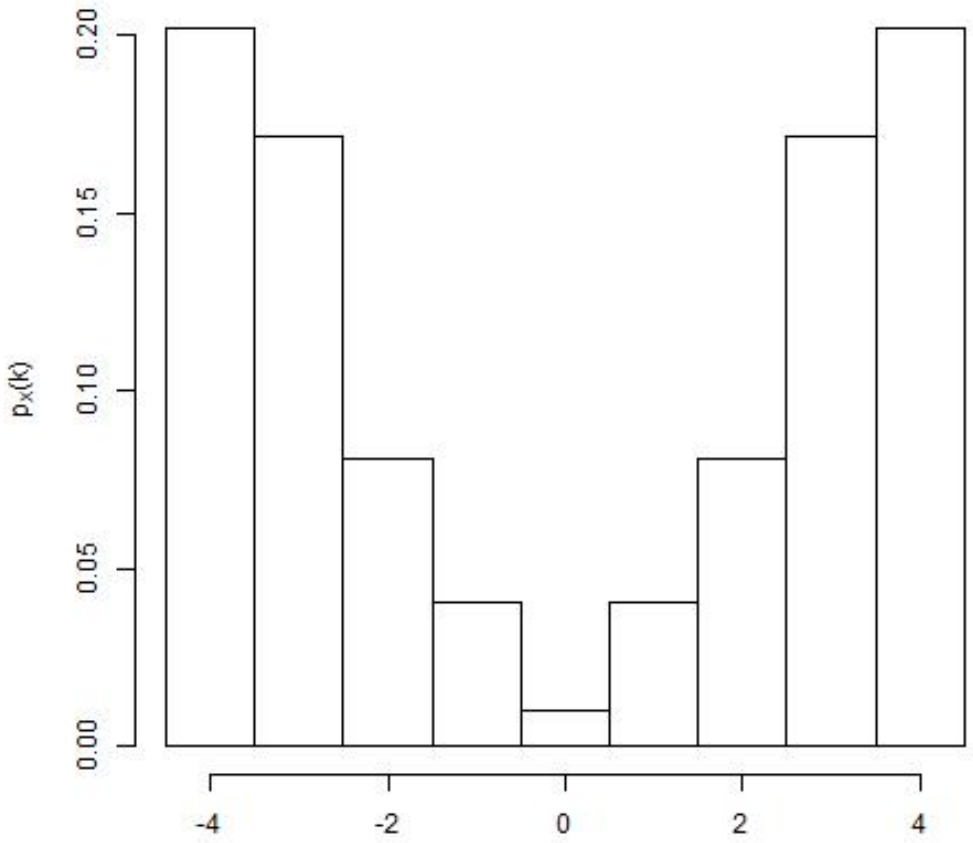

Calculamos

$$E[X] = \sum_{k=-4}^{4} k p_X(k) = 0$$

$$E[X^2] = \sum_{k=-4}^{4} k^2 p_X(k) = 10{,}19$$

$$V(X) = E[X^2] - (E[X])^2 = 10{,}19$$

Ejemplo: dos variables discretas comparables

Y variable discreta con $R_Y = \{-4, -3, \ldots, 3, 4\}$

k	-4	-3	-2	-1	0	1	2	3	4
$p_Y(k)$	0.01	0.09	0.14	0.17	0.18	0.17	0.14	0.09	0.01

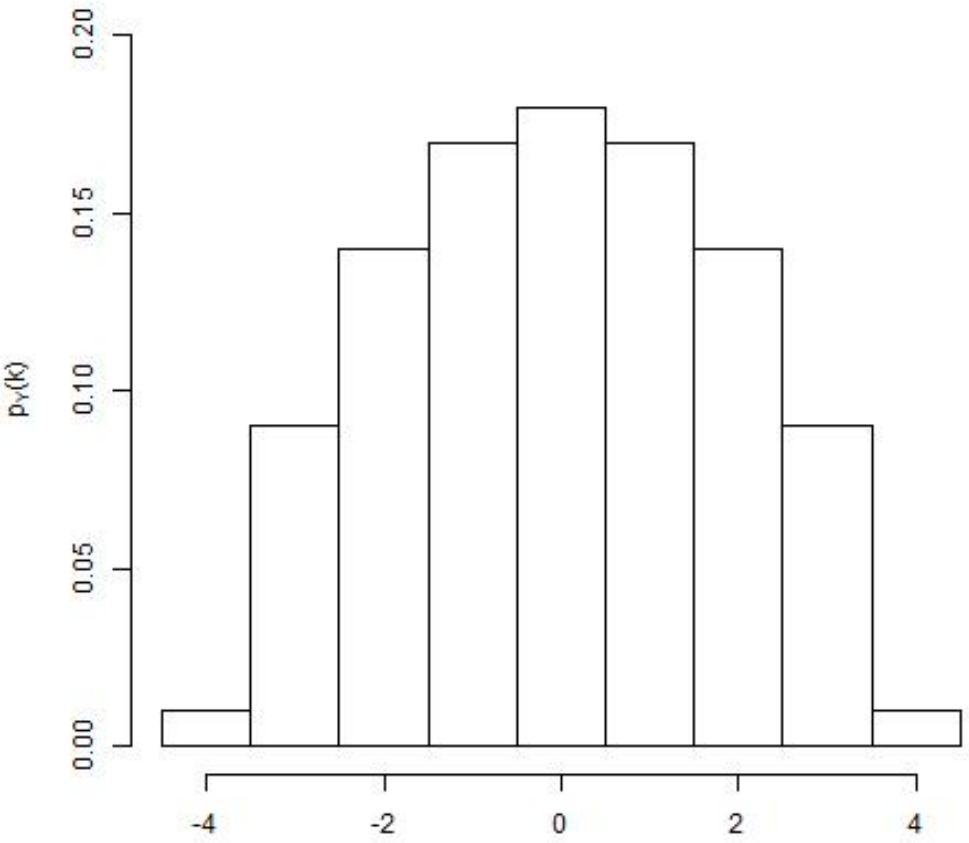

Calculamos

$$E[Y] = \sum_{k=-4}^{4} k p_Y(k) = 0$$

$$E[Y^2] = \sum_{k=-4}^{4} k^2 p_Y(k) = 3{,}4$$

$$V(Y) = E[Y^2] - (E[Y])^2 = 3{,}4$$

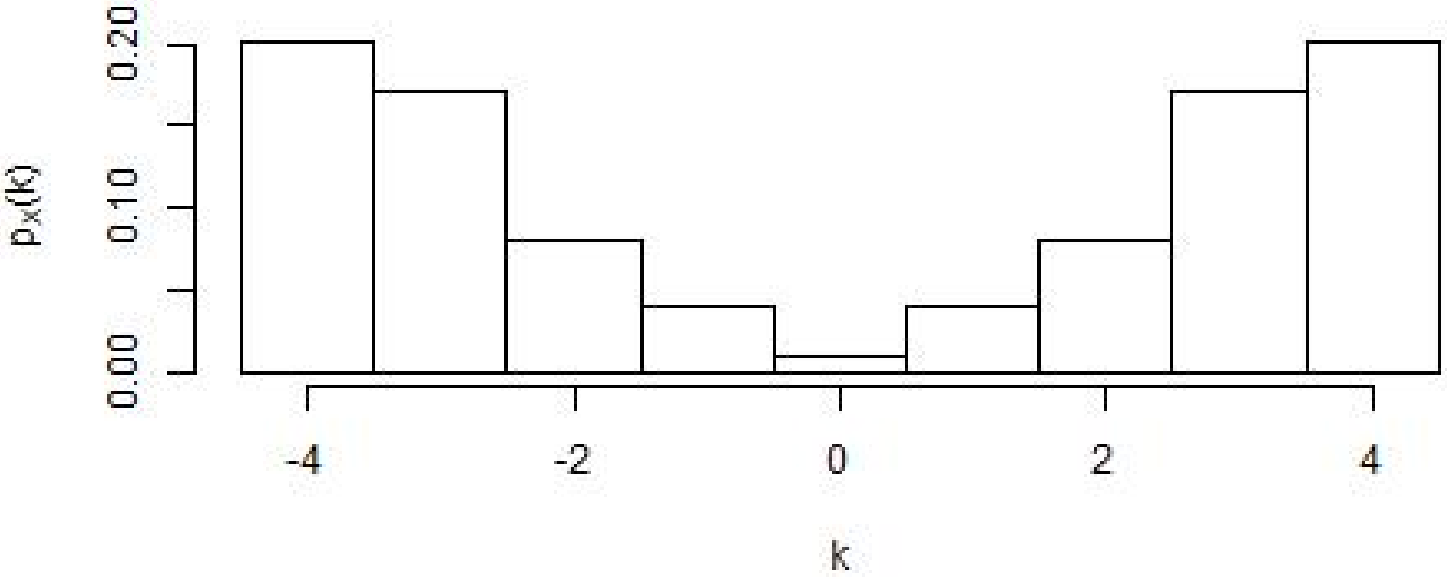

$E(X) = 0$

$V(X) = 10{,}19$

$E(Y) = 0$

$V(Y) = 3{,}4$

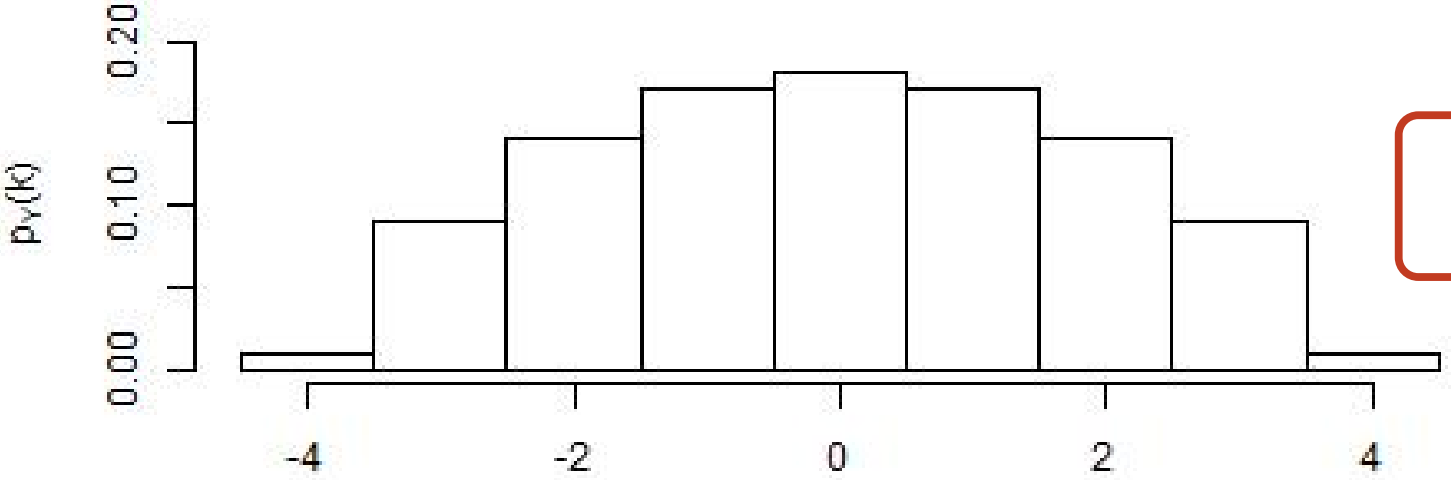

X es más dispersa que Y

$$\boxed{V(X) > V(Y)}$$

Esperanza y varianza de la distribución normal

Sea $Z \sim \mathcal{N}(0,1)$. Queremos hallar $E(Z)$ y $V(Z)$.

$$E(|Z|) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} |y|\, e^{-y^2/2} dy = \frac{2}{\sqrt{2\pi}} \int_{0}^{\infty} y e^{-y^2/2} dy$$
$$= \frac{1}{\sqrt{2\pi}} \left[-e^{-y^2/2} \right] \Big|_0^{\infty} = \frac{1}{\sqrt{2\pi}} [1] < +\infty$$

Luego, la esperanza existe.

$$E(Z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} y e^{-y^2/2} dy = 0$$

por ser la integral de una función integrable e impar, o sea, $h(y) = ye^{-y^2/2} = -h(-y)$.

Esperanza y varianza de la distribución normal

$$E(Z^2) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} y^2 e^{-y^2/2} dy = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \underbrace{[-y]}_{u} \underbrace{\left[-ye^{-y^2/2}\right]}_{v'} dy$$

$$= \frac{1}{\sqrt{2\pi}} \left(\left[\underbrace{-y}_{u} \underbrace{e^{-y^2/2}}_{v} \right] \Bigg|_{-\infty}^{\infty} - \int_{-\infty}^{\infty} \underbrace{(-1)}_{u'} \underbrace{e^{-y^2/2}}_{v} dy \right)$$

$$= \underbrace{\frac{1}{\sqrt{2\pi}} \left[-ye^{-y^2/2}\right]_{-\infty}^{\infty}}_{=0} + \underbrace{\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-y^2/2} dy}_{=1} = 1$$

Luego,

$$E(Z) = 0 \quad V(Z) = 1$$

Esperanza y varianza de la distribución normal

Sea $\boxed{X \sim \mathcal{N}\left(\mu, \sigma^2\right).}$ Queremos hallar $E(X)$ y $V(X)$.Por el Corolario 4.6 (estandarización de la normal) sabemos que $Z = (X - \mu)/\sigma \sim \mathcal{N}(0,1)$ tiene distribución normal estándar. Luego, $X = \sigma Z + \mu$ y sabemos que $E(Z) = 0$ y $V(Z) = 1$. Finalmente, por linealidad de la esperenza tenemos,

$$\boxed{E(X) = \sigma E(Z) + \mu = \mu,}$$

y por la Propiedad V.3 (cambio de escala) resulta

$$\boxed{V(X) = \sigma^2 V(Z) = \sigma^2.}$$

Es decir, que los dos parámetros con los que caracterizamos la distribución normal son su esperanza y su varianza.

Distribución Normal: varianza

a menor varianza, más concentrada

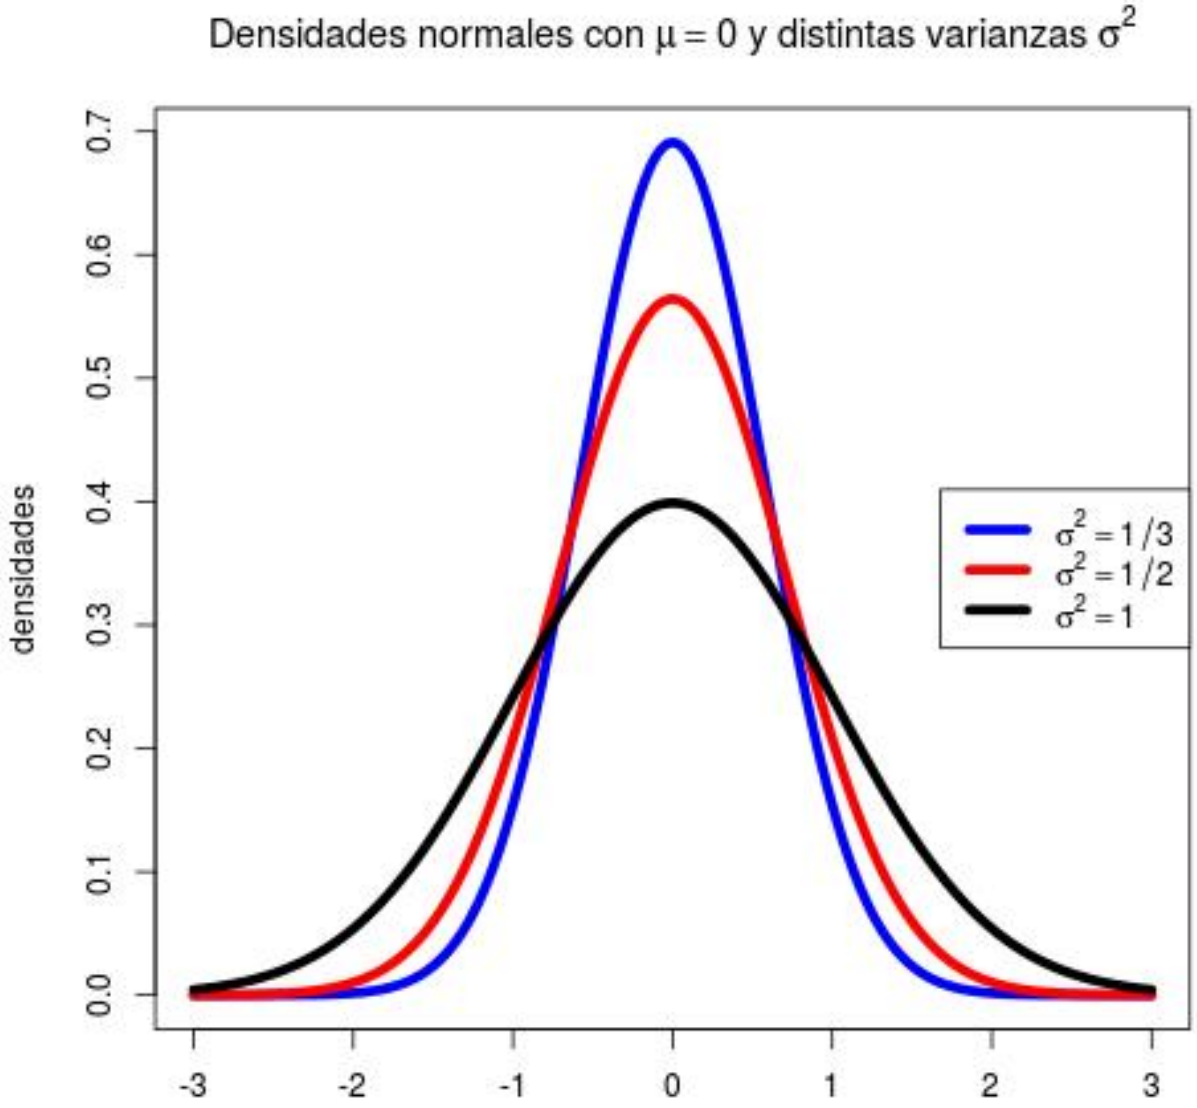

Espacio $\mathcal{L}^2$

Sea $(\Omega, \mathcal{F}, P)$ un espacio de probabilidad. Definimos el espacio

$\boxed{\mathcal{L}^2(\Omega, \mathcal{F}, P)}$ por

$\mathcal{L}^2(\Omega, \mathcal{F}, P) = \left\{X : X \text{ es una variable aleatoria y } E\left[X^2\right] < +\infty\right\}.$

Proposición 6.1

$\mathcal{L}^2(\Omega, \mathcal{F}, P)$ es un espacio vectorial con las operaciones

- *$a \in \mathbb{R}$, $X \in \mathcal{L}^2(\Omega, \mathcal{F}, P)$, entonces aX también está en $\mathcal{L}^2(\Omega, \mathcal{F}, P)$*
- *$X, Y \in \mathcal{L}^2(\Omega, \mathcal{F}, P)$, entonces $X + Y \in \mathcal{L}^2(\Omega, \mathcal{F}, P)$.*

Para probarlo necesitamos probar que se verifican todas las propiedades de espacios vectoriales, por ejemplo:

a) $X = 0 \in \mathcal{L}^2(\Omega, \mathcal{F}, P)$

b) $X, Y \in \mathcal{L}^2(\Omega, \mathcal{F}, P)$, $a, b \in \mathbb{R}$, entonces $aX + bY \in \mathcal{L}^2(\Omega, \mathcal{F}, P)$. O sea que sabiendo que $E\left[X^2\right] < +\infty$, $E\left[Y^2\right] < +\infty$ queremos probar que $E\left[(aX + bY)^2\right] < +\infty$.

Sabiendo que $E\left[X^2\right] < +\infty$, $E\left[Y^2\right] < +\infty$ qvq $E\left[(aX+bY)^2\right] < +\infty$.
Sabemos que para todo α, $\beta \in \mathbb{R}$, vale

$$(\alpha+\beta)^2 \leq 2\alpha^2 + 2\beta^2 \qquad \text{¡comprobarlo!}$$

Luego $(aX+bY)^2 \leq 2a^2X^2 + 2b^2Y^2$ (desigualdad de funciones). Por la monotonía de la esperanza, y la linealidad, tenemos

$$E\left[(aX+bY)^2\right] \leq E\left[2a^2X^2 + 2b^2Y^2\right] = 2a^2E\left[X^2\right] + 2b^2E\left[Y^2\right] < +\infty$$

Espacio $\mathcal{L}^2$

Lema 6.10 (desigualdad de Cauchy – Schwarz)

$X, Y \in \mathcal{L}^2(\Omega, \mathcal{F}, P)$, *entonces* $[E(XY)]^2 \leq E\left(X^2\right) E\left(Y^2\right)$.
La igualdad vale si y sólo si $P(aX = bY) = 1$ *para* $a, b \in \mathbb{R}$, *al menos uno de los cuales es distinto de cero.*

Demostración.

Si $E\left(Y^2\right) = 0$, como Y^2 es una variable positiva con esperanza 0, por el Lema 6.7 resulta que $Y^2 = 0$, luego $Y = 0$ y el lado izquierdo de la desigualdad que queremos probar vale 0 (el miembro derecho es siempre positivo). Más aun, vale la igualdad y tenemos $P(Y = 0) = 1$.
Si $E\left(Y^2\right) \neq 0$, sea
$g(t) = E\left([X + tY]^2\right) = E\left(X^2\right) + 2tE(XY) + t^2 E\left(Y^2\right)$. g es una función cuadrática, $g : \mathbb{R} \to \mathbb{R}_{\geq 0}$. Por ser positiva, puede tener a lo sumo una raíz real. Y su discriminante es ≤ 0.
$\Delta = 4\left[E(XY)\right]^2 - 4E\left(Y^2\right) E\left(X^2\right) \leq 0$, y probamos la desigualdad. $\square$

Espacio $\mathcal{L}^2$

Demostración.

¿Cuándo vale la igualdad? $[E(XY)]^2 - E\left(Y^2\right)E\left(X^2\right) = 0 \Leftrightarrow \Delta = 0$ si y sólo si la cuadrática tiene exactamente una raíz real, lo cual ocurre si y sólo si existe un t_0 tal que

$$g(t_0) = E\left([X + t_0 Y]^2\right) = 0$$

De nuevo, por el Lema 6.7, como $[X + t_0 Y]^2$ es una variable positiva que tiene esperanza cero, resulta que $[X + t_0 Y]^2 = 0$ con probabilidad 1, luego $P\left(X = -t_0 Y\right) = 1$. $\square$

Observación 6.1

Si $X \in \mathcal{L}^2$, entonces $E\left[|X|\right] < +\infty$ pues, por la desigualdad de Cauchy – Schwarz tomando $Y = 1 \in \mathcal{L}^2$, tenemos

$$[E(|X|)]^2 = [E(|X|\, Y)]^2 \leq E(X^2)E(Y^2) = E(X^2)E(1) = E(X^2) < +\infty$$

Espacio $\mathcal{L}^2$: producto interno

Proposición 6.2

$\langle X, Y\rangle = E[XY]$ *define un producto interno en* $\mathcal{L}^2(\Omega, \mathcal{F}, P)$.

La existencia de $\langle X, Y\rangle$ está garantizada por la desigualdad de Cauchy – Schwarz. Y además, resulta

- $\langle X, Y\rangle$ es bilineal, es decir,

$$E\left[(aX + bY)Z\right] = aE\left[XZ\right] + bE\left[YZ\right]$$

- $\langle X, Y\rangle$ es simétrico: trivial
- $\langle X, Y\rangle$ es definido positivo: sea X no nula (o sea, $P(X = 0) \neq 1$), entonces $\langle X, X\rangle > 0$.

Espacio $\mathcal{L}^2$: norma

El producto interno define una norma en $\mathcal{L}^2(\Omega, \mathcal{F}, P)$,

$$\boxed{\|X\|^2 = \langle X, X\rangle = E\left(X^2\right)} \qquad \text{ó } \|X\| = \sqrt{E\left(X^2\right)}.$$

y queda entonces definida la distancia

$$\|X - Y\| = \sqrt{E\left[(X-Y)^2\right]}$$

La desigualdad triangular es consecuencia de la desigualdad de Cauchy – Schwarz, $\|X+Y\|^2 \leq (\|X\| + \|Y\|)^2$

$$\begin{aligned}
\|X+Y\|^2 &= E\left[(X+Y)^2\right] = E\left[X^2\right] + E\left[Y^2\right] + 2E\left[XY\right] \\
&\leq E\left[X^2\right] + E\left[Y^2\right] + 2\left|E\left[XY\right]\right| \\
&\leq E\left[X^2\right] + E\left[Y^2\right] + 2\sqrt{E\left[X^2\right]}\sqrt{E\left[Y^2\right]} \\
&= \left(\sqrt{E\left[X^2\right]} + \sqrt{E\left[Y^2\right]}\right)^2 = (\|X\| + \|Y\|)^2
\end{aligned}$$

Podemos formalizar lo hecho antes

Proposición 6.3

Sea $X \in \mathcal{L}^2(\Omega, \mathcal{F}, P)$, entonces $\mu = E[X]$ es la constante que mejor aproxima a X en el sentido que

$$E\left[(X-\mu)^2\right] \leq E\left[(X-c)^2\right], \quad \forall c \in \mathbb{R}$$

Demostración.

$$\begin{aligned}
E\left[(X-c)^2\right] &= E\left[(X-\mu+\mu-c)^2\right] \\
&= E\left[(X-\mu)^2 + (\mu-c)^2 + 2(X-\mu)(\mu-c)\right] \\
&= E\left[(X-\mu)^2\right] + E\left[(\mu-c)^2\right] + E\left[2(X-\mu)(\mu-c)\right] \\
&= E\left[(X-\mu)^2\right] + (\mu-c)^2 + 2(\mu-c)\,E\left[X-\mu\right] \\
&= E\left[(X-\mu)^2\right] + (\mu-c)^2 \geq E\left[(X-\mu)^2\right] \quad \text{si } c \neq \mu.
\end{aligned}$$

□

Covarianza

Definición 6.5 (covarianza)

Dadas dos variables aleatorias X e $Y \in \mathcal{L}^2(\Omega, \mathcal{F}, P)$, se define la **covarianza** *entre ellas mediante la fórmula*

$$Cov(X, Y) = E\Big[(X - \mu_X)(Y - \mu_Y)\Big] \,,$$

siendo $\mu_X = E[X]$ y $\mu_Y = E[Y]$.

Lema 6.11 (Fórmula reducida para la covarianza)

$$Cov(X, Y) = E[XY] - E[X]E[Y] \,.$$

Demostración.

$$Cov(X, Y) = E\left[(X - \mu_X)(Y - \mu_Y)\right] = E\left[XY - \mu_X\, Y - \mu_Y\, X + \mu_X\, \mu_Y\right]$$

Covarianza: propiedades

Teorema 6.12

Si X e Y son independientes, entonces

$$Cov(X, Y) = 0$$

Demostración.

Por el Lema 6.8 (esperanza de producto de variables independientes), tenemos que

$$\begin{aligned} Cov(X, Y) &= E\Big[\underbrace{(X - \mu_X)}_{g(X)}\underbrace{(Y - \mu_Y)}_{h(Y)}\Big] \\ &= E\left[g(X)\right] E\left[h(Y)\right] = \underbrace{E\left[X - \mu_X\right]}_{=0}\underbrace{E\left[Y - \mu_Y\right]}_{=0} = 0 \end{aligned}$$

□

Covarianza

¡Cuidado! Covarianza cero ¡NO garantiza independencia!

Ejercicio 6.1

Sea $X \sim \mathcal{U}(-1,1)$. *Sea* $Y = X^2$. *Demuestre que* $Cov(X,Y) = 0$. *¿Son las variables* X *e* Y *independientes?*
Sugerencia: calcule $P(X > 1/2, Y < 1/4)$.

Covarianza: interpretación del signo

$$Cov(X,Y) = E\Big[(X-\mu_X)(Y-\mu_Y)\Big]$$

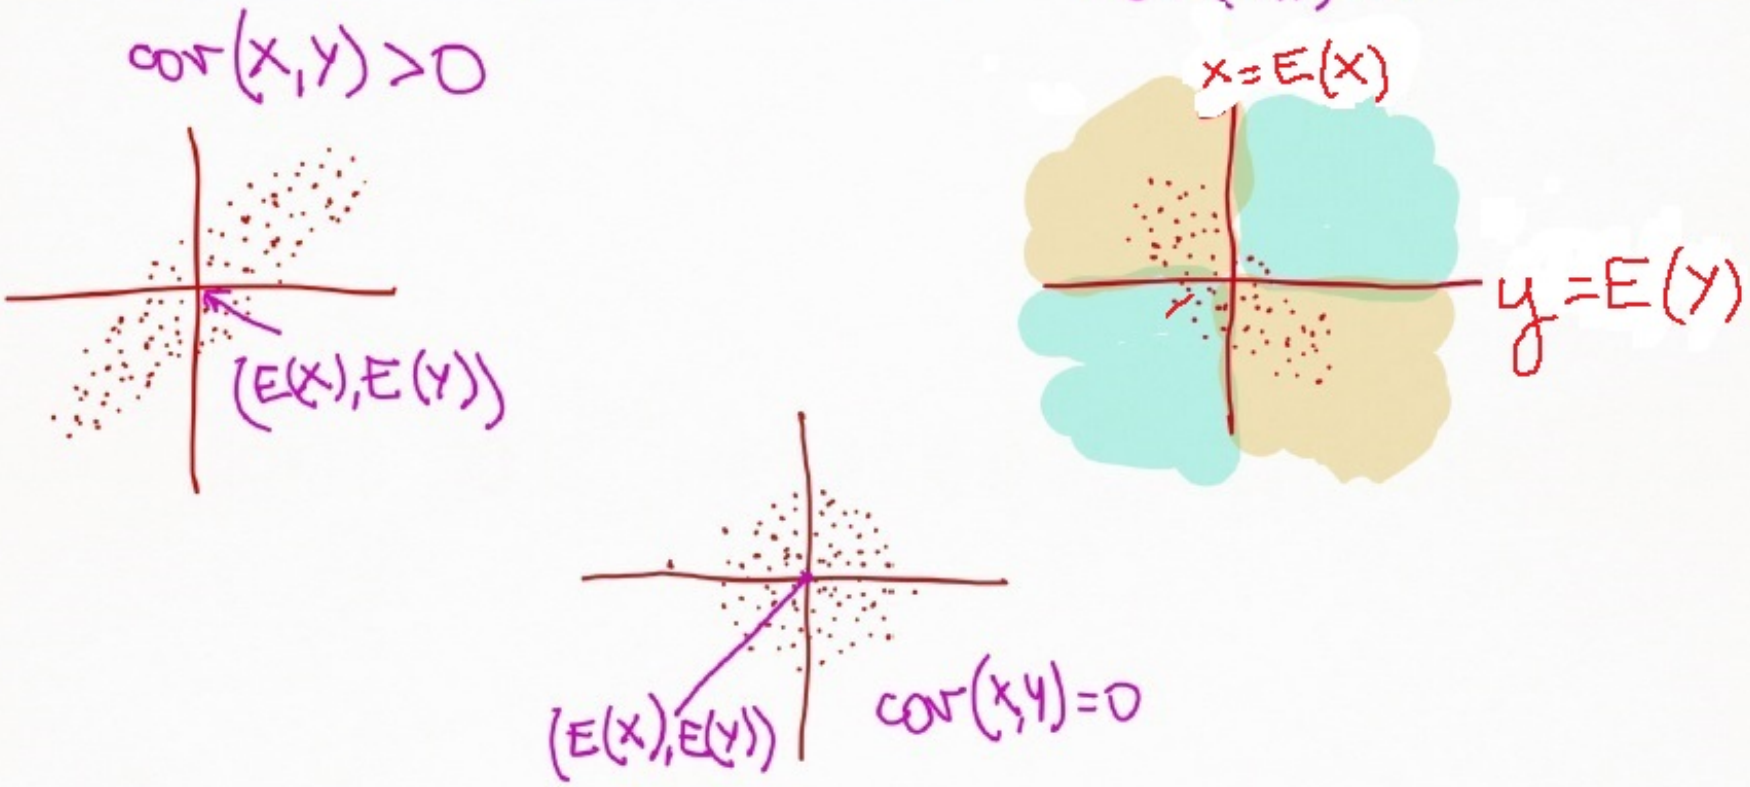

Covarianza

Lema 6.13

La covarianza verifica las siguientes propiedades:

1. $\mathrm{Cov}(X, Y) = \mathrm{Cov}(Y, X)$
2. $\mathrm{Cov}(X, X) = V(X)$
3. $\mathrm{Cov}(a + X, Y) = \mathrm{Cov}(X, Y), \quad a \in \mathbb{R}$
4. $\mathrm{Cov}(aX, bY) = a\ b\ \mathrm{Cov}(X, Y), \quad a,\ b \in \mathbb{R}$
5. $\mathrm{Cov}(X, Y + Z) = \mathrm{Cov}(X, Y) + \mathrm{Cov}(X, Z)$
6. $\mathrm{Cov}(\sum_{i=1}^{n} a_i\ X_i, \sum_{j=1}^{m} b_j\ Y_j) = \sum_{i=1}^{n} \sum_{j=1}^{m} a_i\ b_j\ \mathrm{Cov}(X_i, Y_j)$, *con* $a_i,\ b_j \in \mathbb{R}$
7. $V(X + Y) = V(X) + V(Y) + 2\,\mathrm{Cov}(X, Y)$

3)

$$\begin{aligned}\mathrm{Cov}(a+X,Y) &= E\left([a+X-E(a+X)][Y-E(Y)]\right)\\ &= E\left([X-E(X)][Y-E(Y)]\right) = \mathrm{Cov}(X,Y)\end{aligned}$$

4) Como $E(ax) = aE(X)$,

$$\begin{aligned}\mathrm{Cov}(aX,bY) &= E\left([aX-aE(X)][bY-bE(Y)]\right)\\ &= E\left(ab[X-E(X)][Y-E(Y)]\right)\\ &= abE\left([X-E(X)][Y-E(Y)]\right)\\ &= ab\,\mathrm{Cov}(X,Y)\end{aligned}$$

5) Consideremos $\mathrm{Cov}(X, Y+Z)$

$$\begin{aligned}\mathrm{Cov}(X,Y+Z) &= E\left([X-E(X)]\{[Y-E(Y)]+[Z-E(Z)]\}\right)\\ &= E\left([X-E(X)][Y-E(Y)]+[X-E(X)][Z-E(Z)]\right)\\ &= E\left([X-E(X)][Y-E(Y)]\right)\\ &+ E\left([X-E(X)][Z-E(Z)]\right) = \mathrm{Cov}(X,Y)+\mathrm{Cov}(X,Z)\end{aligned}$$

6) Lo obtenemos combinando 1), 4) y 5) .

Covarianza: propiedades

Faltaba probar

7) $V(X+Y) = V(X) + V(Y) + 2\,\mathrm{Cov}(X,Y)$

Demostración.

$V(X+Y) = \mathrm{Cov}(X+Y, X+Y) = \mathrm{Cov}(X,X) + \mathrm{Cov}(X,Y) + \mathrm{Cov}(Y,X) + \mathrm{Cov}(Y,Y) = V(X) + V(Y) + 2\,\mathrm{Cov}(X,Y)$ □

Ejercicio 6.2

Escribir la fórmula de $V(X-Y)$.

Ejercicio 6.3

Usar la propiedad 7 para calcular la varianza de una $X \sim \mathcal{B}(n,p)$

Covarianza: propiedades

Lema 6.14 (Cauchy–Schwarz para covarianza)

$|\mathrm{Cov}(Z,W)|^2 \leq V(Z)V(W)$.
La igualdad vale si y sólo si $P\left(a_1 Z = a_2 W + a_3\right) = 1$ *para* $a_1, a_2, a_3 \in \mathbb{R}$ *con* $a_1 \neq 0$ *ó* $a_2 \neq 0$.

Demostración.

Usamos el Lema 6.10, con $X = Z - \mu_Z$ e $Y = W - \mu_W$,

$$\begin{aligned}|\mathrm{Cov}(Z,W)|^2 &= |E\left[(Z-\mu_Z)(W-\mu_W)\right]|^2 = [E(XY)]^2 \\ &\leq E\left(X^2\right)\ E\left(Y^2\right) = E\left[(Z-\mu_Z)^2\right]\ E\left[(W-\mu_W)^2\right] \\ &= V(Z)V(W).\end{aligned}$$

El Lema 6.10 afirma que la igualdad vale si y sólo si $P\left(aX = bY\right) = 1$ para $a, b \in \mathbb{R}$, al menos uno de los cuales es distinto de cero. O sea $a(Z-\mu_Z) = b(W-\mu_W)$, con lo cual la afirmación vale. □

Covarianza de la normal bivariada

Un vector aleatorio (X, Y) tiene distribución normal bivariada si su función de densidad conjunta es

$$f_{XY}(x,y) = \frac{1}{C} e^{-\frac{1}{2(1-\rho^2)}\left[\left(\frac{x-\mu_X}{\sigma_X}\right)^2 + \left(\frac{y-\mu_Y}{\sigma_Y}\right)^2 - 2\rho\left(\frac{x-\mu_X}{\sigma_X}\right)\left(\frac{y-\mu_Y}{\sigma_Y}\right)\right]}.$$

con $C = 2\pi\sigma_X\sigma_Y\sqrt{1-\rho^2}$. Calculemos la $\mathrm{Cov}(X, Y)$.

$$\mathrm{Cov}(X,Y) = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} (x-\mu_X)(y-\mu_Y) f_{XY}(x,y)dxdy$$

Haciendo el cambio de variables $u = (x-\mu_X)/\sigma_X$ y $v = (y-\mu_Y)/\sigma_Y$ con Jacobiano $\sigma_X\sigma_Y$

$$\frac{\cdot\sigma_X\sigma_Y}{2\pi\sqrt{1-\rho^2}}\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} uv \exp\left[-\frac{1}{2(1-\rho^2)}\left(u^2+v^2-2\rho uv\right)\right] dudv$$

Covarianza de la normal bivariada

Para calcular la integral, completamos cuadrados en u. Usamos la igualdad:

$$u^2 + v^2 - 2\rho uv = (u - \rho v)^2 + v^2\left(1 - \rho^2\right)$$

Entonces, podemos reemplazar en la integral que teníamos

$$\frac{\cdot\sigma_X\sigma_Y}{2\pi\sqrt{1-\rho^2}}\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} uv\exp\left[-\frac{1}{2\left(1-\rho^2\right)}\left(u^2+v^2-2\rho uv\right)\right]dudv$$

y obtener

$$\frac{\sigma_X\sigma_Y}{2\pi\sqrt{1-\rho^2}}\int_{-\infty}^{\infty} v\exp\left(-v^2/2\right)\left(\int_{-\infty}^{\infty} u\exp\left[-\frac{1}{2\left(1-\rho^2\right)}(u-\rho v)^2\right]du\right)dv$$

La **integral interior** es la esperanza de una v.a. $\mathcal{N}\left(\rho v, \left(1-\rho^2\right)\right)$, a la que únicamente le falta la constante de normalización $\left[2\pi\left(1-\rho^2\right)\right]^{-1/2}$, y por lo tanto tenemos

$$\mathrm{Cov}(X,Y) = \rho\sigma_X\sigma_Y\int_{-\infty}^{\infty}\frac{1}{\sqrt{2\pi}}v^2e^{-v^2/2}dv = \rho\sigma_X\sigma_Y$$

(la expresión azul es la varianza de la normal estándar, que es 1)

Correlación

Definición 6.6 (coeficiente de correlación)

Dadas dos variables aleatorias X e Y definimos el **coeficiente de correlación** *entre ellas mediante la fórmula*

$$\rho(X,Y) = \frac{Cov(X,Y)}{\sqrt{V(X)V(Y)}}.$$

Decimos que X e Y son **no correlacionadas** cuando $Cov(X,Y)=0$. La covarianza no es por sí misma una medida muy satisfactoria de la dependencia entre X e Y, pues el valor que toma se ve afectado por cambios de la escala de las variables, $Cov(aX,Y) = aCov(X,Y)$. El siguiente Lema muestra que eso no pasa con la correlación, lo cual la hace más interpretable.

Propiedades de la Correlación

Lema 6.15

$$-1 \leq \rho(X, Y) \leq 1$$

Además, $|\rho(X, Y)| = 1$ *si y sólo si existen constantes* $a, b \in \mathbb{R}$ *para las cuales* $P(Y = aX + b) = 1$.

Demostración.

Es una consecuencia del Lema 6.14. □

Lema 6.16

$$\rho(aX, bY) = \rho(X, Y), \quad \forall a, b \in \mathbb{R}.$$

Ejercicio 6.4

Probar el Lema 6.16.

Ejercicio 6.5

Sea $(X, Y) \sim \mathcal{N}_2\left((\mu_X, \mu_Y), \begin{bmatrix} \sigma_X^2 & \rho\sigma_X\sigma_Y \\ \rho\sigma_X\sigma_Y & \sigma_Y^2 \end{bmatrix}\right)$, *un vector aleatorio normal bivariado. Basándonos en las cuentas que ya hicimos, deducir el valor de* $\rho(X, Y)$.

El coeficiente de correlación $\rho(X, Y)$ mide la fuerza de la relación lineal. entre X e Y (compárese con los gráficos de las curvas de nivel que hicimos en el capítulo de vectores aleatorios). La correlación también afecta la apariencia de un diagrama de dispersión, o *scatterplot* que se construye generando n pares independientes (X_i, Y_i), donde $i = 1, \ldots, n$ y luego graficándolos. La figura que sigue muestra diagramas de dispersión de 100 pares de observaciones de variables aleatorias normales bivariadas pseudoaleatorias para varios valores de ρ. Observemos que las nubes de puntos tienen una forma aproximadamente elíptica.

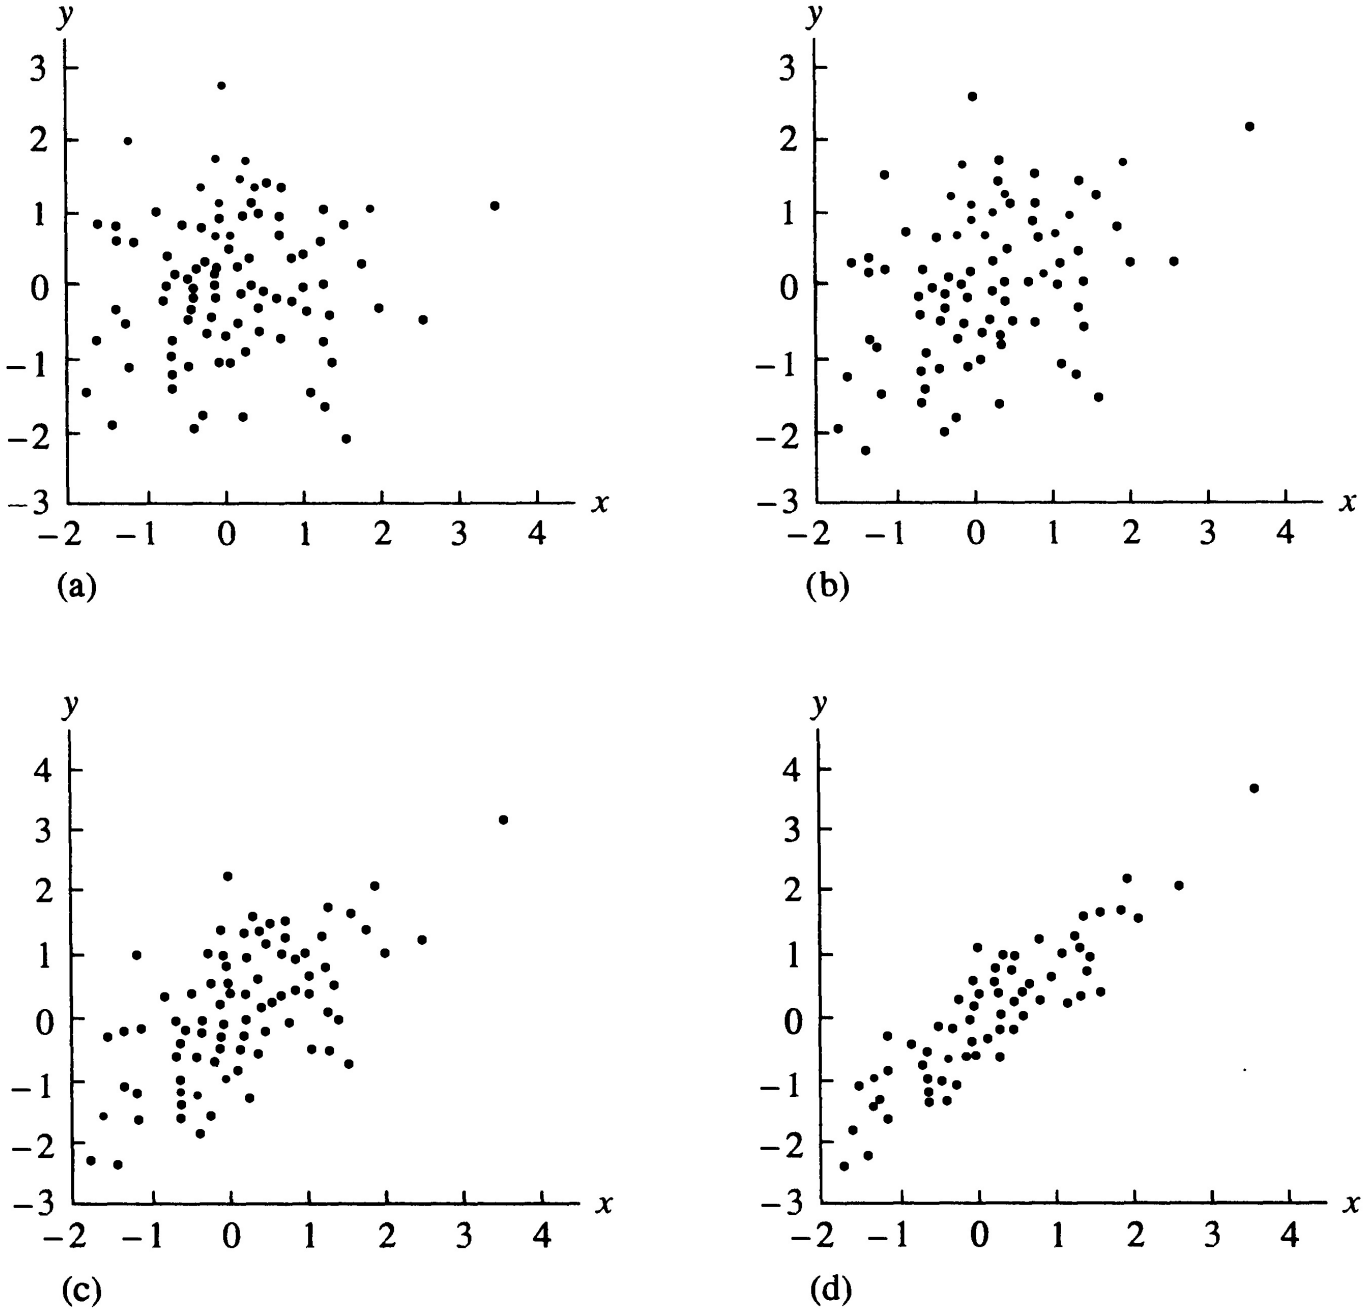

(a) $\rho = 0$
(b) $\rho = 0{,}3$
(c) $\rho = 0{,}6$
(d) $\rho = 0{,}9$